

Monitoramento Dinâmico do Volume Hídrico em Reservatórios Utilizando Imagens de Satélite e Redes Neurais Convolucionais

Ariane Marina de Albuquerque Teixeira



UNIVERSIDADE FEDERAL DA PARAÍBA
CENTRO DE INFORMÁTICA
PROGRAMA DE PÓS-GRADUAÇÃO EM INFORMÁTICA

Ariane Marina de Albuquerque Teixeira

Monitoramento Dinâmico do Volume Hídrico em Reservatórios Utilizando Imagens de Satélite e Redes Neurais Convolucionais

Dissertação de Mestrado apresentada ao Programa
de Pós-graduação em Informática do Centro de Informática,
da Universidade Federal da Paraíba, como requisito parcial
para a obtenção do título de Mestre em Informática.

Orientador: Prof. Dr. Leonardo Vidal Batista

Fevereiro de 2024

**Catalogação na publicação
Seção de Catalogação e Classificação**

T266m Teixeira, Ariane Marina de Albuquerque.
Monitoramento dinâmico do volume hídrico em
reservatórios utilizando imagens de satélite e redes
neurais convolucionais / Ariane Marina de Albuquerque
Teixeira. - João Pessoa, 2024.
80 f. : il.

Orientação: Leonardo Vidal Batista.
Dissertação (Mestrado) - UFPB/CI.

1. Sensoriamento remoto - Satélites. 2. Simulação de
reservatórios. 3. Monitoramento de reservatórios. 4.
Aprendizado profundo. I. Batista, Leonardo Vidal. II.
Título.

UFPB/BC

CDU 528.837:629.783(043)



Ata da Sessão Pública de Defesa de Dissertação de Mestrado de Ariane Marina de Albuquerque Teixeira, candidata ao título de Mestre em Informática na área de Sistemas de Computação, realizada em 30 de janeiro de 2024.

Aos trinta dias do mês de janeiro do ano de dois mil e vinte e quatro, às 16:30h, no Centro de Informática da Universidade Federal da Paraíba, reuniram-se os membros da Banca Examinadora constituída para julgar o Trabalho Final da discente Ariane Marina de Albuquerque Teixeira, vinculada a esta Universidade sob a matrícula nº 20211023824, candidata ao grau de Mestre em Informática, na área de “*Sistemas de Computação*”, na linha de pesquisa “*Sinais, Sistemas Digitais e Gráficos*”, do Programa de Pós-Graduação em Informática. A comissão examinadora foi composta pelos professores: Leonardo Vidal Batista, Orientador e Presidente; Thais Gaudencio do Rego, Examinadora Interna; Celso Augusto Guimaraes Santos, Examinador Externo ao Programa; Richarde Marques da Silva, Examinador Externo ao Programa. Dando início aos trabalhos, o Presidente da Banca cumprimentou os presentes, comunicou a finalidade da reunião e passou a palavra à candidata para que ela fizesse a exposição oral do trabalho de dissertação intitulado **“Monitoramento Dinâmico do Volume Hídrico em Reservatórios Utilizando Imagens de Satélite e Redes Neurais Convolucionais”**. Concluída a exposição, a candidata foi arguida pela Banca Examinadora que emitiu o seguinte parecer: **“aprovada”**. Do ocorrido, eu, Iguatemi Eduardo da Fonseca, Vice-Coordenador do Programa de Pós-Graduação em Informática, lavrei a presente ata que vai assinada por mim e pelos membros da Banca Examinadora. João Pessoa, 30 de janeiro de 2024.

Documento assinado digitalmente

gov.br IGUATEMI EDUARDO DA FONSECA
Data: 26/02/2024 14:06:48-0300
Verifique em <https://validar.itd.gov.br>

Prof. Dr. Iguatemi Eduardo da Fonseca

Documento assinado digitalmente

gov.br LEONARDO VIDAL BATISTA
Data: 06/02/2024 11:35:52-0300
Verifique em <https://validar.itd.gov.br>

Documento assinado digitalmente

gov.br THAIS GAUDENCIO DO REGO
Data: 08/02/2024 17:18:58-0300
Verifique em <https://validar.itd.gov.br>

Documento assinado digitalmente

gov.br CELSO AUGUSTO GUIMARAES SANTOS
Data: 08/02/2024 14:03:40-0300
Verifique em <https://validar.itd.gov.br>

Documento assinado digitalmente

gov.br RICHARDE MARQUES DA SILVA
Data: 08/02/2024 14:20:13-0300
Verifique em <https://validar.itd.gov.br>

Prof. Dr. Leonardo Vidal Batista
Orientador (PPGI-UFPB)

Profª. Drª. Thais Gaudencio do Rego
Examinadora Interna (PPGI-UFPB)

Prof. Dr. Celso Augusto Guimaraes Santos
Examinador Externo à Instituição (UFPB)

Prof. Dr. Richarde Marques da Silva
Examinador Externo à Instituição (UFPB)

”É justo que muito custe o que muito vale.”

- Santa Teresa D'Ávila

AGRADECIMENTOS

Agradeço a Deus por sempre me guiar e por proporcionar saúde e força ao longo desta jornada.

Aos meus pais, Erica e Jair, expresso minha profunda gratidão pelo amor, carinho e ensinamentos que me conduziram até o ponto em que estou hoje.

Aos meus irmãos, Ariely e Arisson, agradeço pela constante ajuda, união, parceria e amizade, mesmo estando fisicamente distantes na maioria das vezes.

A Victor, meu companheiro de vida, dedico meu agradecimento por todo o amor, carinho, paciência e parceria em todos os momentos, e por sempre acreditar no meu potencial.

Aos meus amigos, que estiveram ao meu lado, agradeço por compartilharmos juntos risos, desafios e conquistas ao longo dos anos de amizade.

Ao meu orientador, Prof. Dr. Leonardo Vidal Batista, expresso minha gratidão especial por todo o aprendizado, apoio, confiança e parceria ao longo do mestrado, bem como pela orientação deste trabalho.

Ao Prof. Dr. Celso Augusto Guimarães Santos, agradeço por todo auxílio. À Prof. Dra. Thaís Gaudencio do Rêgo, pelas valiosas contribuições. Ao Prof. Dr. Richarde Marques da Silva, por todo conhecimento compartilhado. Também estendo meus agradecimentos aos professores que compõem o corpo docente do Programa de Pós-graduação em Informática (PPGI) pelos ensinamentos enriquecedores proporcionados.

À Agência Executiva de Gestão das Águas (AESÁ), em nome de Jana Yres, Alexandre Magno e Pedro Freire, agradeço pelo fornecimento dos dados que possibilitaram a realização deste trabalho.

Por fim, agradeço a todos que contribuíram, direta ou indiretamente, para minha formação pessoal e profissional.

RESUMO

Técnicas de monitoramento baseadas em imagens têm sido aplicadas para realizar o acompanhamento do volume de água. O principal objetivo deste trabalho é apresentar um *framework* que aproveita o aprendizado profundo e imagens multiespectrais para monitorar os volumes de água de reservatórios no estado da Paraíba, Brasil. Para validar a metodologia, foram selecionados seis reservatórios distintos ao longo do estado: Engenheiro Ávidos, Argemiro de Figueiredo, Lagoa do Arroz, Gramame/Mamuaba, Sumé e Marés. Uma Rede Neural Convolucional (CNN) foi empregada para extrair a área da superfície dos corpos d'água, utilizando imagens de satélite. O gráfico de monitoramento de volume foi derivado dos dados de área da superfície da água dos reservatórios, juntamente com o uso das respectivas curvas CAV. Foram empregadas imagens multiespectrais de satélite que abrangem o período de meados de 2018 a 2023. Quatro abordagens distintas foram testadas na criação do modelo de segmentação, com todos os testes conduzidos usando a técnica de validação cruzada com 5 *folds*. O modelo baseado na U-Net, com a técnica de aumento de dados, obteve as melhores métricas, com resultados de 95,81% *IoU* e 96,86% de coeficiente de *Dice*. As séries temporais dos volumes de água destacaram variações significativas no desempenho do modelo de segmentação entre os reservatórios, com alguns, como Argemiro de Figueiredo e Engenheiro Ávidos, revelando resultados de MAPE inferiores a 15% e coeficientes de *Pearson* maiores que 0,92, enquanto outros, como Marés e Gramame/Mamuaba, apresentaram métricas inferiores. A análise permitiu avaliar a eficácia do modelo e da metodologia, identificando fatores que podem afetar a precisão das estimativas, como a presença de nuvens, a resolução espacial das imagens de satélite e a localização geográfica dos reservatórios.

Palavras-chave: aprendizado profundo, sensoriamento remoto, simulação de reservatórios, monitoramento de reservatórios.

ABSTRACT

Image-based monitoring techniques have been applied to track water volume. The main objective of this work is to present a framework that leverages deep learning and multispectral images to monitor water volumes in reservoirs in Paraíba, Brazil. To validate the methodology, six different reservoirs throughout the state were selected: Engenheiro Ávidos, Argemiro de Figueiredo, Lagoa do Arroz, Gramame/Mamuaba, Sumé, and Marés. A Convolutional Neural Network (CNN) was employed to extract the surface area of water bodies using satellite images. The volume monitoring graph was derived from the reservoirs' water surface area data, along with their respective elevation-area-volume (EAV) curves. Multispectral satellite images covering the period from mid-2018 to 2023 were employed. Four distinct approaches were tested in creating the segmentation model, with all tests conducted using 5-fold cross-validation. The U-Net-based model, with data augmentation technique, achieved the best metrics, with results of 95.81% IoU and 96.86% Dice coefficient. The temporal series of water volumes highlighted significant variations in the segmentation model performance among the reservoirs, with some, such as Argemiro de Figueiredo and Engenheiro Ávidos, revealing MAPE results below 15% and Pearson coefficients greater than 0.92. In contrast, others, such as Marés and Gramame/Mamuuba, showed inferior metrics. The analysis allowed for evaluating the effectiveness of the model and methodology, identifying factors that may affect the accuracy of estimates, such as cloud presence, spatial resolution of satellite images, and geographical location of the reservoirs.

Key-words: deep learning, remote sensing, reservoir simulation, reservoir monitoring.

LISTA DE FIGURAS

1	Densidade de pequenos reservatórios de água.	21
2	Estrutura de uma rede neural artificial simples.	25
3	Estrutura de uma rede neural profunda simplificada.	26
4	Estrutura de uma CNN.	27
5	Representação da Camada de Convolução.	27
6	Representação da Camada de <i>Pooling</i>	28
7	Função de ativação ReLu.	29
8	Função de ativação <i>sigmoid</i>	30
9	Ilustração do efeito <i>dropout</i> em uma rede neural. a) Rede neuronal padrão com 2 camadas ocultas. b) Exemplo da aplicação do <i>dropout</i> na rede da esquerda.	31
10	Representação da Arquitetura U-Net.	33
11	Metodologia adotada na pesquisa.	34
12	Mapa do estado da Paraíba com a localização dos seis reservatórios escolhidos.	35
13	Reservatório Engenheiro Ávidos em 22 de junho de 2020.	36
14	Reservatório Argemiro de Figueiredo em 25 de agosto de 2020.	37
15	Reservatório Lagoa do Arroz em 7 de julho de 2020.	38
16	Reservatório Gramame-Mamuaba em 26 de junho de 2021.	39
17	Reservatório Sumé em 4 de julho de 2020.	40
18	Reservatório Marés em 04 de dezembro de 2019.	41
19	Exemplo de uma imagem do conjunto de dados utilizado. a) Visualização das bandas B2, B3 e B4 de uma imagem do conjunto de dados. b) A máscara correspondente.	43
20	Pré-processamento das imagens do conjunto de dados. a) Imagem original. b) Imagem com o <i>padding</i> . c) Imagem após o processo de corte.	44
21	Formação dos conjuntos de dados.	45
22	Divisão do conjunto de dados para o treinamento do modelo.	46
23	Passos para obter o modelo em cada teste.	48

24	Máscara dos reservatórios. a) Engenheiro Ávidos. b) Argemiro de Figueiredo. c) Lagoa do Arroz. d) Gramame/Mamuaba. e) Sumé. f) Marés.	52
25	Representação gráfica de um corte de um reservatório.	53
26	Exemplos das previsões geradas pelo modelo do Teste 2 no conjunto de teste	58
27	Exemplos da imagem do reservatório Engenheiro Ávidos com suas respectivas máscaras obtidas pela rede.	59
28	A série temporal obtida para o reservatório Engenheiro Ávidos, comparando-o com os dados disponibilizados pela AESA.	59
29	Exemplos da imagem do reservatório Argemiro de Figueiredo com suas respectivas máscaras obtidas pela rede.	60
30	A série temporal obtida para o reservatório Argemiro de Figueiredo, comparando-o com os dados disponibilizados pela AESA.	60
31	Exemplos da imagem do reservatório Lagoa do Arroz com suas respectivas máscaras obtidas pela rede.	61
32	A série temporal obtida para o reservatório Lagoa do Arroz, comparando-o com os dados disponibilizados pela AESA.	61
33	Exemplos da imagem do reservatório Gramame/Mamuaba com suas respectivas máscaras obtidas pela rede.	62
34	A série temporal obtida para o reservatório Gramame/Mamuaba, comparando-o com os dados disponibilizados pela AESA.	62
35	Exemplos da imagem do reservatório Sumé com suas respectivas máscaras obtidas pela rede.	63
36	A série temporal obtida para o reservatório Sumé, comparando-o com os dados disponibilizados pela AESA.	63
37	Exemplos da imagem do reservatório Marés com suas respectivas máscaras obtidas pela rede.	64
38	A série temporal obtida para o reservatório Marés, comparando-o com os dados disponibilizados pela AESA.	64

LISTA DE TABELAS

1	Dimensões e indicadores do índice de segurança hídrica (ISH)	19
2	Reservatórios paraibanos divididos por capacidade hídrica.	20
3	Bandas espectrais do sensor MSI do satélite Sentinel-2.	24
4	Características do reservatório Engenheiro Ávidos.	36
5	Características do reservatório Argemiro de Figueiredo.	37
6	Características do reservatório Lagoa do Arroz.	38
7	Características do reservatório Gramame-Mamuaba.	39
8	Características do reservatório Sumé.	40
9	Características do reservatório Marés.	41
10	Valores dos hiperparâmetros utilizados no treinamento do modelo de classificação.	47
11	Resultados dos testes realizados em segmentação de água nas medidas de IoU e <i>Dice</i>	57
12	Resultados dos testes realizados em segmentação de água nas demais medidas.	57
13	Resultados dos testes realizados em segmentação de água nas demais medidas.	65
14	Cota x Área x Volume do Reservatório Engenheiro Ávidos.	77
15	Cota x Área x Volume do Reservatório Argemiro de Figueiredo.	78
16	Cota x Área x Volume do Reservatório Lagoa do Arroz.	79
17	Cota x Área x Volume do Reservatório Gramame/Mamuaba.	80
18	Cota x Área x Volume do Reservatório Sumé.	81
19	Cota x Área x Volume do Reservatório Marés.	81

LISTA DE ABREVIATURAS

- AESA – Agência Executiva de Gestão das Águas do Estado da Paraíba
- ANA – Agência Nacional de Águas
- BOA – Base da Atmosfera - do inglês, *Bottom Of Atmosphere*
- CAGEPA – Companhia de Água e Esgotos da Paraíba
- CNN – Rede neural convolucional - do inglês, *Convolutional Neural Network*
- DNOCS - Departamento Nacional de Obras Contra as Secas
- ESA – Agência Espacial Europeia - do inglês, *European Space Agency*
- ESWKB – *Earth Surface Water Knowledge Base*
- GEE – *Google Earth Engine*
- ISH – Índice de Segurança Hídrica
- MLP – Perceptron de Múltiplas Camadas - do inglês, *Multilayer Perceptron*
- MSI – Instrumento Multiespectral - do inglês, *MultiSpectral Instrument*
- PNSH – Plano Nacional de Segurança Hídrica
- ReLU – Unidades Lineares Retificadas - do inglês, *Rectified Linear Units*
- TOA – Topo da Atmosfera - do inglês, *Top Of Atmosphere*

Sumário

1 INTRODUÇÃO	15
1.1 Objetivos	17
1.1.1 Objetivos Específicos	17
2 CONCEITOS GERAIS E REVISÃO DA LITERATURA	18
2.1 Reservatórios Hídricos na Paraíba e o Abastecimento de Água	18
2.1.1 Segurança Hídrica	18
2.1.2 Reservatórios Paraibanos	20
2.2 Sensoriamento Remoto	21
2.2.1 Missão Sentinel-2	23
2.3 Redes Neurais Artificiais	24
2.3.1 Redes Neurais Convolucionais	26
2.3.1.1 Camada convolucionais	27
2.3.1.2 Pooling	28
2.3.1.3 Camadas completamente conectadas	28
2.3.1.4 Funções de ativações	29
2.3.1.5 Aumento de dados	30
2.3.1.6 Adam	30
2.3.1.7 <i>Dropout</i>	30
2.3.1.8 <i>Flatten</i>	31
2.3.1.9 Aprendizado por Transferência	31
2.4 Segmentação de Imagens	32
2.4.1 U-Net	32
3 MATERIAIS E MÉTODOS	34
3.1 Área de Estudo	34
3.1.1 Reservatório Engenheiro Ávidos	35
3.1.2 Reservatório Argemiro de Figueiredo	36
3.1.3 Reservatório Lagoa do Arroz	37

3.1.4	Reservatório Gramame-Mamuaba	38
3.1.5	Reservatório Sumé	39
3.1.6	Reservatório Marés	40
3.1.7	Obtenção das Imagens	42
3.2	Segmentação das Imagens de Satélites	42
3.2.1	Conjunto de Dados da Rede	43
3.2.2	Arquitetura da Rede	44
3.2.3	Método do Treino da Rede	46
3.2.4	Abordagens Utilizadas	47
3.2.5	Métricas de Avaliação	49
3.2.5.1	Acurácia	49
3.2.5.2	Índice de Jaccard (IoU)	49
3.2.5.3	Coeficiente <i>Dice</i>	50
3.2.5.4	Precisão e Revocação	50
3.2.5.5	Pontuação F1	50
3.3	Criação da Série Temporal do Volume dos Reservatórios	51
3.3.1	Cálculo do Espelho d'Água	51
3.3.2	Estimativa do Volume Armazenado	52
3.3.3	Pós-processamento da Série Temporal Obtida	53
3.3.4	Métricas Utilizadas na Avaliação dos Resultados	53
3.3.4.1	Erro Médio Quadrático (RMSE - <i>Root Mean Square Error</i>)	54
3.3.4.2	Erro Percentual Médio Absoluto (MAPE - <i>Mean Absolute Percentage Error</i>)	54
3.3.4.3	Coeficiente de Determinação (R^2)	54
3.3.4.4	Coeficiente de Correlação de <i>Pearson</i>	55
4	RESULTADOS E DISCUSSÕES	56
4.1	Segmentação de Imagens de Satélites	56
4.2	Série Temporal do Volume dos Reservatórios	58
5	CONSIDERAÇÕES FINAIS	67

REFERÊNCIAS	68
ANEXO A - CURVAS COTA × ÁREA × VOLUME	77

1 INTRODUÇÃO

Águas doces superficiais representam apenas uma pequena porção dos recursos hídricos existentes no planeta. No entanto, por serem as mais acessíveis, seu valor econômico e social para a população humana é inestimável. Além disso, fornecem uma variedade de serviços ecossistêmicos abrangentes para toda a vida (PEKEL et al., 2016; POSTEL et al., 1996). Essa importância das águas superficiais é particularmente evidente em regiões sujeitas a eventos de seca extrema, como a região semiárida do Brasil, que sofreu com chuvas abaixo da média nos últimos anos (CUNHA et al., 2019). Esses eventos de seca impactaram severamente tanto a economia, quanto a vida da população da região (ZHANG et al., 2021).

Na Paraíba, a seca tem causado impactos significativos, afetando tanto o aspecto social, quanto o econômico da população, principalmente nas áreas rurais (MEDEIROS; BRITO, 2017). Os prejuízos da falta de água na região atingem desde a segurança hídrica, até a produção de alimentos e a criação de animais. Dada a pouca disponibilidade de água subterrânea e vazões fluviais, os reservatórios hídricos são as principais fontes de abastecimento de água na Paraíba (MAMEDE et al., 2012). Em face dessa realidade de escassez hídrica e da crítica importância dos corpos d'água superficiais para a saúde humana e a gestão eficaz dos recursos hídricos, é essencial considerar o avanço do Sensoriamento Remoto e o uso de satélites, que têm contribuído para um melhor monitoramento desses recursos.

Com o crescente número de satélites em órbita, os produtos de imageamento da superfície do planeta estão oferecendo resoluções espaciais e temporais cada vez melhores (YAN et al., 2017). Esse avanço, combinado com a disponibilidade de uma ampla gama de produtos de imageamento, resultou em um aumento substancial na quantidade de dados de sensoriamento remoto disponíveis para quem busca informações valiosas relacionadas à cobertura terrestre. Atualmente, a utilização do Sensoriamento Remoto para o estudo e monitoramento dos recursos hídricos é bastante diversificada e se mostra de grande relevância. Medições por satélites e outras plataformas também podem ser usadas como fonte de informações para permitir o mapeamento das águas superficiais do ecossistema aquático em planícies de inundação, rios, canais, lagos e reservatórios (SOUZA et al., 2019a).

Assim, a identificação de corpos d'água apresenta uma gama de aplicações significativas, incluindo a estimativa da disponibilidade hídrica, a delimitação de área inundadas, a detecção de mudanças ambientais (ACHARYA et al., 2016), a avaliação de regiões propensas a inundações (BANDIM; GALVINCIO, 2021) e a distinção entre lagoas costeiras artificiais de aquicultura e salinicultura (DINIZ et al., 2021). Além disso, seu uso é evidenciado em diversas pesquisas, como na classificação de corpos d'água (KO et al., 2015),

no monitoramento da qualidade da água (MACHADO; BAPTISTA, 2016; LOPES et al., 2015; XU et al., 2021), na medição do volume em reservatórios (DUAN; BASTIAANSSEN, 2013; NAMIKAWA, 2015), na análise da temperatura da água (DUGDALE, 2016), na compreensão da dinâmica espacial global da água (PEKEL et al., 2016; KLEIN et al., 2017; YAO et al., 2019; PICKENS et al., 2020), no mapeamento territorial (MARTINS et al., 2007; MOREIRA et al., 2018) e local dos espelhos d'água (TAN et al., 2019; NÓBREGA et al., 2019); bem como na dessecação de lagos (ROKNI et al., 2014; TOURIAN et al., 2015), no mapeamento e monitoramento áreas úmidas (PERENNOU et al., 2018), e na avaliação multitemporal do espelho d'água (SOUZA et al., 2019b).

Deste modo, técnicas de Sensoriamento Remoto e dos seus produtos têm se mostrado extremamente úteis para monitorar e gerenciar os recursos hídricos. Além disso, com o advento das tecnologias como a computação em nuvem, *big data* e Inteligência Artificial, com o uso do aprendizado de máquina - do inglês, *machine learning* - e do aprendizado profundo - do inglês, *deep learning* -, ainda é capaz de analisar grandes áreas em menor tempo e com melhor custo-benefício (BARBOSA et al., 2021).

O aprendizado profundo e a análise de *big data* tornaram-se comuns em muitos campos científicos. Essa mudança de paradigma também está evoluindo rapidamente no campo do sensoriamento remoto. As técnicas de aprendizado profundo, no entanto, são notórias por demandarem uma elevada quantidade de dados e exigir grandes demandas computacionais (MIKOŁAJCZYK; GROCHOWSKI, 2018; KAUSHAL et al., 2019). No contexto das observações aplicadas da Terra, há uma crescente riqueza de dados com componentes adicionados de localização, tempo e dados multimodais (MOU et al., 2017). As plataformas geocomputacionais baseadas em nuvem, como o *Google Earth Engine* (GEE), resolveram muitos dos desafios computacionais e de gerenciamento de dados, centralizando e padronizando os dados em uma estrutura comum, reduzindo a barreira do uso de dados de observação da Terra (GORELICK et al., 2017). O GEE tem sido aproveitado em inúmeros estudos científicos (TASSI; VIZZARI, 2020; CAMPOS-TABERNER et al., 2018; AGUILAR et al., 2018; PARKS et al., 2018). A recente integração de *big data*, com tecnologias de aprendizado profundo, permite a utilização por uma ampla variedade de usuários, incluindo aqueles em disciplinas científicas (MAYER et al., 2021).

Dessa forma, os dados de sensoriamento remoto, aliados com a aprendizagem profunda e a visão computacional, têm sido empregados para resolver problemas de grande complexidade e vêm gerando uma grande contribuição para a obtenção de métodos mais efetivos de controle ambiental (ARROYO-FIGUEROA et al., 2000; PHYS-ORG, 2016; SILVER et al., 2016).

A visão computacional desempenha um papel fundamental nesse contexto, permitindo a análise e interpretação automatizadas de imagens de satélite e outros dados de sensoriamento remoto. Por meio de algoritmos e técnicas avançadas, a visão computa-

cional possibilita a extração de informações relevantes (GAO et al., 2016; WANG et al., 2020; CHEN et al., 2018). Essa abordagem complementa o aprendizado profundo e o uso de *big data*, ampliando ainda mais as capacidades de monitoramento e gestão dos recursos hídricos.

Este trabalho emprega redes neurais convolucionais em conjunto com imagens de satélite como abordagem para monitorar os recursos hídricos. Essa técnica possibilita a análise automatizada de grandes conjuntos de dados de imagens de satélite, com o objetivo de estimar o volume de reservatórios hídricos. A integração de dados de sensoriamento remoto com técnicas avançadas de aprendizado de máquina permite obter conclusões sobre a dinâmica dos recursos hídricos, contribuindo para aprimorar sua gestão e monitoramento.

Apesar das promissoras aplicações dessa técnica, o monitoramento de reservatórios por meio de imagens de satélite enfrenta diversos desafios. Estes incluem variações na cobertura de nuvens, mudanças sazonais na cobertura de água, interferência de outros elementos do terreno e imprecisões nos dados de referência disponíveis.

1.1 Objetivos

O objetivo geral do trabalho é desenvolver uma estrutura baseada em redes neurais convolucionais profundas utilizando imagens multiespectrais da constelação de satélites Sentinel-2 e monitorar o volume de água de reservatórios.

1.1.1 Objetivos Específicos

Para que a solução proposta tenha êxito, faz-se necessário, portanto, que os seguintes objetivos específicos sejam atingidos:

- Segmentar corpos hídricos a partir de imagens de satélites multiespectrais da constelação de satélites Sentinel-2 utilizando Redes Neurais Convolucionais.
- Traçar séries temporais do volume dos reservatórios hídricos selecionados do estado da Paraíba.
- Comparar os resultados obtidos com os resultados disponibilizados mensalmente pela Agência Executiva de Gestão das Águas (AESA).

2 CONCEITOS GERAIS E REVISÃO DA LITERATURA

Este capítulo apresenta os principais conceitos relacionados a este trabalho. Na Seção 2.1, é oferecida uma visão geral dos reservatórios hídricos na Paraíba. A Seção 2.2 explana os principais conceitos de sensoriamento remoto e a missão de satélites utilizada no trabalho. A Seção 2.3 fornece um resumo sobre redes neurais. Por fim, a Seção 2.4 trata a segmentação de imagens.

2.1 Reservatórios Hídricos na Paraíba e o Abastecimento de Água

A gestão dos recursos hídricos no estado da Paraíba enfrenta desafios significativos. A maioria dos rios são intermitentes, com chuvas concentradas em poucos meses do ano e uma variabilidade interanual. Essa situação é agravada pela alternância de anos com chuvas regulares e anos com valores abaixo da média, resultando em secas prolongadas e escassez hídrica aguda. O período entre 2012 e 2016 foi marcado pelo agravamento das condições climáticas em diversas sub-regiões do estado, bem como pelo esgotamento de muitos mananciais superficiais, rios e reservatórios, o que exigiu a implantação de obras emergenciais para garantir o abastecimento de água da população (SEIRHMA, 2021).

A construção de reservatórios de regularização de vazões, que armazenam volumes no período chuvoso para garantir o abastecimento nos períodos de estiagem, é uma solução estratégica que visa aumentar a disponibilidade hídrica. Esses reservatórios têm como finalidade manter a água armazenada durante uma estação seca ou por vários anos. Diante da importância dessas estruturas hídricas, a Agência Nacional de Águas (ANA) realizou um estudo entre 2015 e 2017, com o objetivo de analisar os problemas e as potencialidades dos grandes sistemas de reservatórios da região Nordeste, englobando um total de 204 reservatórios, sendo 46 deles localizados em território paraibano (ANA, 2017).

O estado de Paraíba possui 87% de seu território na região semiárida, onde mais de 81% dos municípios utilizam exclusivamente os mananciais superficiais (rios e reservatórios) como fonte de abastecimento da população, segundo dados do Atlas de Abastecimento Urbano (ANA, 2021a). Portanto, conhecer os recursos disponíveis nos reservatórios e cursos d'água é fundamental não apenas para diminuir o grau de incerteza no processo de tomada de decisão, mas também para garantir a segurança hídrica e o desenvolvimento socioeconômico dessa região.

2.1.1 Segurança Hídrica

A Segurança Hídrica refere-se à capacidade de uma comunidade em garantir acesso sustentável a volumes adequados de água com níveis aceitáveis de qualidade, visando promover o bem-estar humano e o desenvolvimento socioeconômico. Este conceito também

engloba a prevenção de doenças transmitidas pela água, a gestão de desastres relacionados à água e a conservação dos ecossistemas, dentro de um contexto de paz e estabilidade política (UN-WATER, 2013).

A complexidade dos fatores associados à gestão e ao uso da água evidencia a necessidade de estabelecer indicadores de segurança hídrica que, ao mesmo tempo, retratem essas diferenças e possibilitem o fácil entendimento e aplicação por parte de políticas públicas vinculadas à infraestrutura e gestão da água. Nesse sentido, a Agência Nacional de Águas (ANA) desenvolveu o Índice de Segurança Hídrica (ISH) com o propósito de representar de forma clara e direta as múltiplas dimensões da segurança hídrica, integrando o conceito de risco aos diversos usos da água (ANA, 2019).

A composição do ISH foi apresentada no Plano Nacional de Segurança Hídrica (PNSH), o qual avaliou os níveis de segurança hídrica em todo o território brasileiro. Essa conceito foi estruturado em quatro dimensões: humana, econômica, ecossistêmica e de resiliência. Cada uma dessas dimensões são compostas por outros indicadores formados por uma combinação de variáveis mensuráveis (ANA, 2019). A Tabela 1 mostra as dimensões e os indicadores utilizados para compor o ISH.

Tabela 1: Dimensões e indicadores do índice de segurança hídrica (ISH).

DIMENSÃO	INDICADOR
Humana	Garantia de água para abastecimento humano
Econômica	Garantia de água para irrigação e pecuária
	Garantia de água para atividade industrial
Ecossistêmica	Quantidade adequada de água para usos naturais
	Qualidade adequada de água para usos naturais
	Segurança das barragens de rejeito de mineração
Resiliência	Reservação artificial
	Reservação natural
	Potencial de armazenamento subterrâneo
	Variabilidade pluviométrica

Fonte: ANA (2019).

As dimensões humana e econômica do ISH são utilizadas para quantificar os déficits de atendimento às demandas hídricas do abastecimento humano e do setor produtivo. As dimensões ecossistêmica e de resiliência são utilizadas para identificar as áreas mais críticas e vulneráveis (ANA, 2019).

O ISH apresenta cinco níveis para classificar grau de segurança hídrica do Brasil de classificação: máximo, alto, médio, baixo e mínimo. No território do estado da Paraíba, apenas um município entre os 223 está classificado como grau máximo de segurança, o município de Juarez Távora. A maior parte do estado, 73% dos municípios, está classificada com grau de média ou baixa segurança, representando cerca de 80% da população do

estado. Outros 4% da população do estado estão atualmente submetidos no nível Mínimo do ISH, o mais crítico (ANA, 2021b).

Ao analisar os resultados da dimensão de resiliência do ISH para o estado da Paraíba, fica evidente que a maioria das regiões apresenta alta vulnerabilidade. Isso está relacionado à presença de uma porção significativa do estado situada na região semiárida, onde ocorre grande variabilidade e baixas taxas de precipitação, resultando em menor disponibilidade hídrica. Além disso, as características geológicas dessa região não favorecem o armazenamento de águas subterrâneas. Como resultado, o estado requer uma infraestrutura hídrica mais complexa e, em geral, de caráter integrado, com cobertura regional capaz de mitigar a insegurança hídrica.

2.1.2 Reservatórios Paraibanos

De acordo com o Plano Estadual de Recursos Hídricos da Paraíba, o estado apresenta um quantitativo de 9.695 reservatórios hídricos distribuídos em 11 bacias hidrográficas paraibanas. Os reservatórios vão desde pequenos barreiros, em propriedades privadas, até açudes com capacidade para armazenar mais de bilhões de metros cúbicos, sob a responsabilidade do Governo do Estado, sendo a AESA o órgão que monitora os 135 açudes de maior capacidade (PARAÍBA, 2022).

Desses reservatórios, 98% são classificados como pequenos açudes. A Tabela 2 mostra a distribuição dos reservatórios do estado da Paraíba, de acordo com a sua capacidade.

Tabela 2: Reservatórios paraibanos divididos por capacidade hídrica.

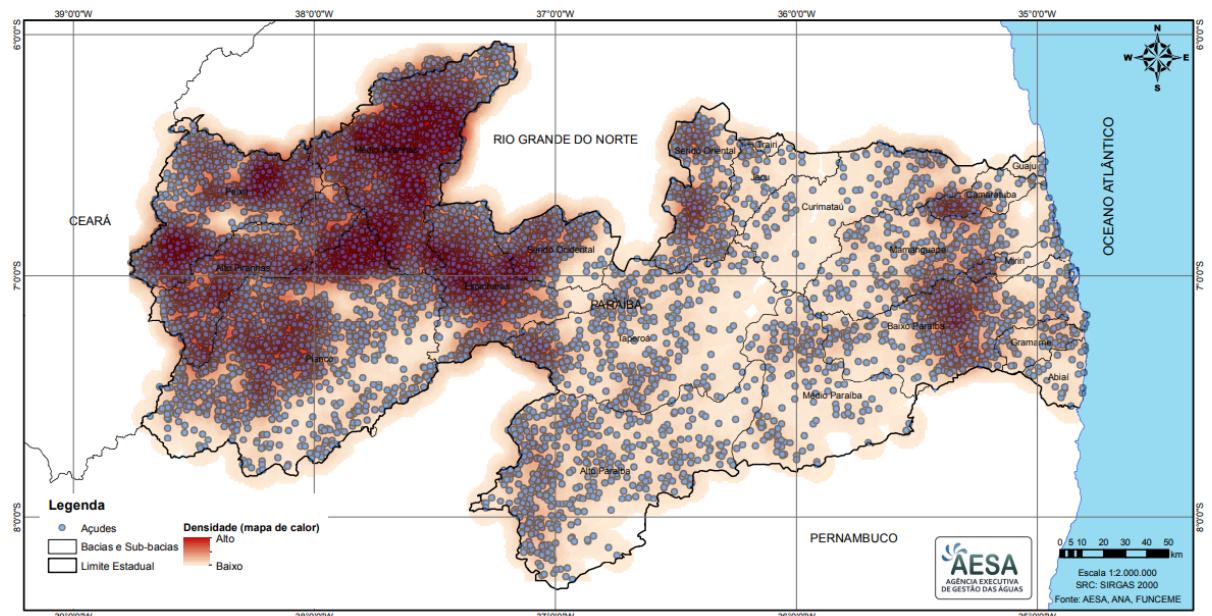
Capacidade	Número de Reservatórios
$\geq 10 \text{ hm}^3$	51
$1 \text{ hm}^3 - 10 \text{ hm}^3$	140
$< 1 \text{ hm}^3$	9504

Fonte: Paraíba (2022).

A Figura 1 mostra a distribuição dos pequenos açudes do estado em forma de mapa de calor. Observa-se a maior densidade desses pequenos açudes na bacia hidrográfica Piranhas e a menor concentração está localizada no litoral paraibano.

Segundo Martins et al. (2007), a utilização de pequenos reservatórios está relacionada à necessidade de distribuição do estoque de água na bacia hidrográfica, uma vez que a disponibilização de recursos hídricos, de forma espacializada, auxilia no desenvolvimento socioeconômico das comunidades difusas.

Figura 1: Densidade de pequenos reservatórios de água.



Fonte: Paraíba (2022).

2.2 Sensoriamento Remoto

Atualmente, dada a grande escala do sistema hídrico do país, os custos financeiros para a realização de monitoramentos e análises técnicas em campo de corpos hídricos são bastante elevados. Como resultado, o sensoriamento remoto tem se mostrado uma ferramenta com maior acessibilidade e de menor custo financeiro para realizar levantamentos técnicos, mapeamentos e monitoramentos para planejamento ambiental e urbano (VILELA, 2010).

De acordo com Maio et al. (2008), o sensoriamento remoto é definido como um conjunto de atividades que permitem a obtenção de informações sobre os objetos que compõem a superfície da Terra, sem que exista o contato físico direto com os mesmos. Essas atividades envolvem a detecção, aquisição e análise (interpretação e extração de informações) da energia eletromagnética refletida e/ou emitida pelos objetos que compõem a superfície terrestre que são detectadas pelos sensores remotos. A energia eletromagnética também pode ser chamada de radiação eletromagnética (NOVO; PONZONI, 2001; MAIO et al., 2008).

A energia eletromagnética é emitida por todos os corpos que apresentam uma temperatura acima do zero grau absoluto (0 Kelvin). O Sol e a Terra são as duas fontes naturais mais importantes dessa energia. A quantidade e a qualidade da energia eletromagnética refletida e emitida pelos objetos terrestres é determinada pelas interações existentes entre eles, ou seja, pelas interações existentes entre a energia eletromagnética e os objetos. Essas interações dependem das propriedades físico-químicas-biológicas dos objetos, e podem ser identificadas nas imagens e nos dados de sensores remotos (MAIO

et al., 2008).

Os sensores remotos são dispositivos capazes de captar a energia eletromagnética proveniente dos objetos que compõe a superfície terrestre, convertendo-a em sinal elétrico passível de ser anotado, e apresentando-a em forma adequada à extração das informações (BARROS et al., 2016). Estes sensores podem estar acoplados tanto em aeronaves (gerando fotografias aéreas), quanto a bordo de satélites (gerando imagens). Além disso, eles podem operar em uma variedade de faixas do espectro eletromagnético, variando do visível até ao infravermelho próximo, para fotografias aéreas, e do visível ao termal, para os sensores orbitais (LIU, 2015).

Atualmente, as técnicas de sensoriamento remoto são amplamente utilizadas por geógrafos, engenheiros, ambientalistas e pesquisadores de várias ciências para o planejamento territorial, possibilitando a análise dos recursos naturais, transportes, comunicações, energia e planejamento urbano e rural (MORATO et al., 2008; PEDRASSOLI, 2011). Aliado à enorme gama de produtos e informações que as técnicas de sensoriamento remoto podem gerar, elas também proporcionam baixo custo, em comparação com outras formas de pesquisa que exigem atividades de campo, maior volume de informação ao longo do tempo, além de uma boa qualidade, permitindo a visualização unificada do ambiente, entre outras vantagens (NOVO, 1992; BARROS et al., 2016).

Dentre os principais satélites utilizados para o monitoramento da cobertura terreste, destacam-se aqueles com sensores multiespectrais, como MODIS, Landsat-8 e Sentinel-2, cada um com seu próprio conjunto de características, como resolução temporal, espectral e espacial (LÓ, 2022).

Pesquisas anteriores demonstraram o uso bem-sucedido de produtos de sensoriamento remoto no monitoramento de reservatórios hídricos, incluindo a estimativa do volume de água. Por exemplo, Abileah et al. (2011) combinaram imagens ópticas do Landsat e dados de altímetros de radar de satélites, para monitorar a capacidade de água de um reservatório remotamente. Sua abordagem foi aplicada com sucesso no Lago Nasser durante um período de seis anos. Outro estudo, conduzido por Avisse et al. (2017), propôs uma abordagem que utilizou imagens Landsat e modelos digitais de elevação (DEM, do inglês *Digital Elevation Model*) para recuperar informações sobre variações de armazenamento em reservatórios de irrigação. Esta abordagem eliminou a necessidade de medições *in situ* e foi aplicada com sucesso na bacia de Yarmouk, na Jordânia.

Além do Landsat, outro satélite amplamente utilizado é o Sentinel. Gourgouletis et al. (2022), com base nas missões Sentinel-2 e 3, demonstraram a eficiência da combinação de estimativas de nível e área de água obtidas por sensoriamento remoto para estimar a variação do armazenamento de água do reservatório de Yliki, na Grécia. Os resultados mostraram uma correlação extremamente alta com o armazenamento monitorado *in situ*.

e o nível de água derivado de satélite, atingindo 98,81% e 99,27%, respectivamente. A variação do armazenamento de água foi estimada e comparada com a série temporal observada, resultando em um erro médio quadrático que representa 1,28% da capacidade do reservatório e uma correlação de 96,14%.

2.2.1 Missão Sentinel-2

O Sentinel-2 foi projetado para missões de observação da Terra e faz parte do Programa Europeu Copernicus, criado e administrado pela Agência Espacial Europeia (ESA, do inglês *European Space Agency*). Seus dados têm sido utilizados em uma ampla gama de trabalhos, nas mais diversas áreas, por se tratar de um sistema com cobertura global, com alta resolução espacial, temporal e espectral, além de acesso gratuito. Alguns exemplos incluem seu uso na monitorização de mudanças no uso da terra, estudos de vegetação e agricultura de precisão, análise de desastres naturais e muito mais.

Lançada em 2015, a missão tem como propósito disponibilizar imagens multiespectrais de alta resolução de maneira ágil e acessível. Essa iniciativa permite aprimorar o gerenciamento ambiental, o monitoramento e a compreensão dos impactos das mudanças climáticas, além de facilitar o gerenciamento de serviços de emergência e desastres, e prover assistência à segurança civil (ESA, 2022).

A missão é formada por uma constelação de dois satélites imageadores idênticos (Sentinel-2A e Sentinel-2B), que orbitam em fase de 180°, reduzindo o tempo de revisita ao mesmo ponto. A resolução temporal de cada satélite é de 10 dias ou de 5 dias, se for considerada a alternância dos dois satélites. Os satélites cruzam a linha do equador às 10:30 do horário local, com objetivo de manter uma similaridade com os dados da série Landsat e SPOT, além de obter menor cobertura de nuvens e boa iluminação solar (ESA, 2022; SOTHE et al., 2017).

A missão Sentinel-2 faz parte de um conjunto de missões divididas em 5 famílias de satélites: a missão Sentinel-1, equipada com radar de abertura sintética, compreendendo a banda C; a missão Sentinel-2, aparelhada com um imageador multiespectral; a missão Sentinel-3, constituído por um par de satélites destinados a medir diversos parâmetros do mar e da terra; e as missões Sentinel-4 e Sentinel-5, voltadas à aquisição de dados da composição atmosférica (ESA, 2022; ASCHBACHER; MILAGRO-PéREZ, 2012).

Ambos os satélites Sentinel-2 (2A e 2B) possuem o sensor Instrumento Multiespectral - do inglês *MultiSpectral Instrument* (MSI) - com resoluções espaciais de 10 m, 20 m ou 60 m, dependendo da faixa espectral de imageamento, como apresentadas na Tabela 3. As bandas azul, verde, vermelho e infravermelho próximo possuem resolução espacial de 10 m e resolução radiométrica de 12 bits (ESA, 2022).

Os dados provenientes do sensor MSI/Sentinel-2 são disponibilizados ao público

Tabela 3: Bandas espectrais do sensor MSI do satélite Sentinel-2.

Banda	Nome	Comprimento de onda central (nm)	Resolução (m)
B01	Aerossol	442,7	60
B02	Azul	492,4	10
B03	Verde	559,8	10
B04	Vermelho	664,6	10
B05	<i>Red edge 1</i>	704,1	20
B06	<i>Red edge 2</i>	740,5	20
B07	<i>Red edge 3</i>	782,8	20
B08	Infravermelho próximo	832,8	10
B08A	<i>Red edge 4</i>	864,7	20
B09	Vapor d'água	945,1	60
B10	Cirrus	1373,5	60
B11	Infravermelho ondas curtas 1	1613,7	20
B12	Infravermelho ondas curtas 2	2202,4	20

Fonte: ESA (2022).

com processamento de Nível-1C (Level-1C), o que implica na aplicação da correção de refletância no Topo da Atmosfera - do inglês, *Top Of Atmosphere* (TOA). No entanto, é possível realizar uma correção de refletância na Base da Atmosfera - do inglês, *Bottom Of Atmosphere Reflectance* (BOA) -, resultando no processamento de Nível-2A (Level-2A). Para realizar essa correção, é utilizado o software Sentinel-2 *Atmospheric Correction* (Sen2Cor) (LOUIS et al., 2016). As imagens são ortorretificadas na projeção UTM/WGS84 e subdivididas em tiles com dimensões de $100 \times 100 \text{ km}^2$ (ESA, 2022; EMDE et al., 2016).

O Sentinel-2 se destaca na aplicação de técnicas de aprendizado profundo, como redes neurais convolucionais (CNNs, do inglês, *Convolutional Neural Networks*), para diversas tarefas de processamento de imagens, incluindo segmentação e monitoramento de recursos hídricos. Graças aos dados de alta resolução espacial e cobertura global fornecidos por essa missão, ela se torna uma fonte indispensável para essas aplicações.

2.3 Redes Neurais Artificiais

Redes neurais artificiais (RNAs) surgiram na década de 40, quando McCulloch e Pitts desenvolveram o primeiro modelo neural. Desde então, o interesse por RNAs cresceu, resultando no desenvolvimento de vários algoritmos, amplamente aplicados em diversas áreas (BRAHME, 2014).

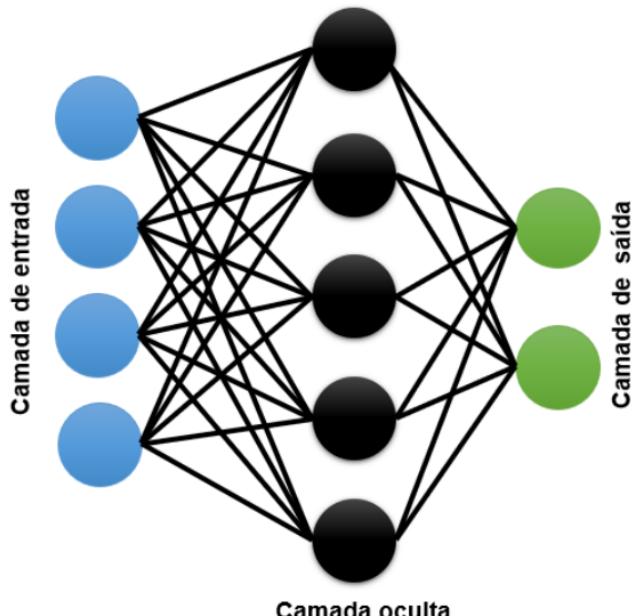
As RNAs têm como intuito resolver problemas complexos que requerem um processamento intensivo. Conforme descrito por Haykin (2001), uma RNA é um modelo

computacional composto por diversos neurônios artificiais interconectados, sendo uma técnica eficaz de aprendizado de máquina amplamente empregada em tarefas como classificação, reconhecimento de padrões e previsão.

Uma das principais características de uma rede neural artificial é sua capacidade de aprender com as entradas fornecidas. Essas redes podem ser treinadas tanto por meio de aprendizado supervisionado, onde dados rotulados são apresentados para a rede aprender a classificar novos dados, quanto por meio de aprendizado não supervisionado, onde a rede é capaz de descobrir padrões por conta própria. De acordo com Santos (2017), as redes neurais têm a capacidade de processar múltiplas entradas simultaneamente e distribuí-las de forma organizada. As informações processadas pela rede são compartilhadas entre suas unidades de processamento.

Os neurônios são unidades simples, não lineares, conectadas em camadas sequenciais. A saída de uma camada é a entrada da próxima camada (RODRIGUES et al., 2021). A Figura 2 apresenta uma representação da organização em camadas de uma RNA simples.

Figura 2: Estrutura de uma rede neural artificial simples.



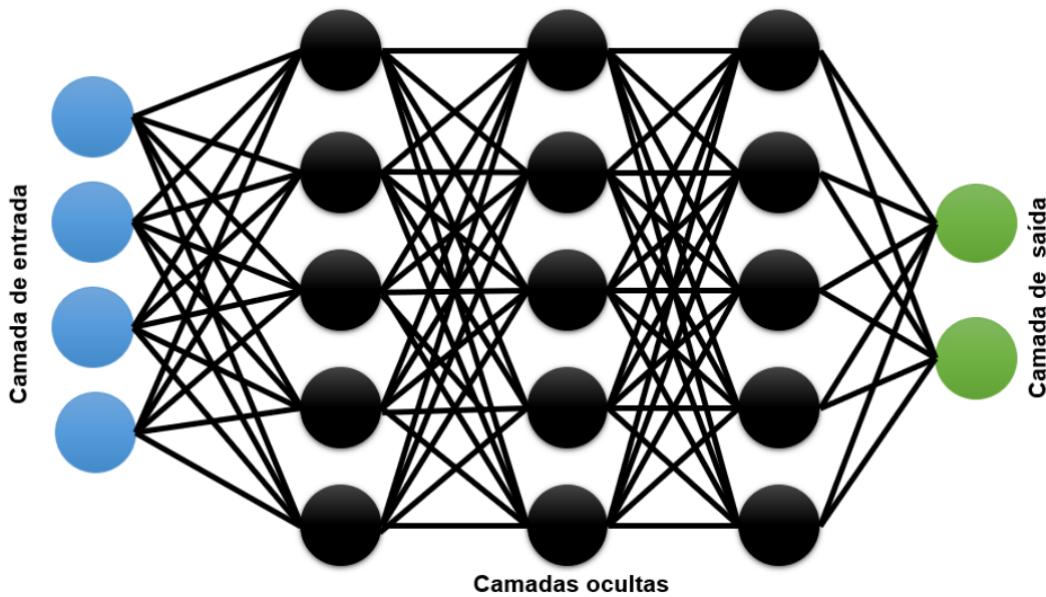
Fonte: Farias (2023).

Na estrutura de uma rede neural, a primeira camada é denominada camada de entrada, sendo responsável por receber os dados brutos que serão processados pela rede. As camadas intermediárias, conhecidas como camadas ocultas, compreendem neurônios que realizam transformações nos dados, gerando uma representação abstrata (LECUN et al., 2015). Por fim, a camada de saída desempenha geralmente a função de classificação dos dados de entrada, embora essa atribuição possa variar em diferentes configurações de rede.

2.3.1 Redes Neurais Convolucionais

As Redes Neurais Convolucionais são redes neurais artificiais de aprendizado profundo, em que se aplica a operação de convolução em pelo menos uma de suas camadas (GUYON; ELISSEEFF, 2006). As CNNs são modelos biologicamente inspirados que podem aprender características de forma hierárquica (LECUN et al., 2015). Elas foram projetadas para lidar com dados bidimensionais, como imagens em formato matricial, e utilizam operações de convolução para extrair informações das camadas subsequentes (SCHMIDHUBER, 2015). As camadas ocultas de uma CNN desempenham predominantemente dois tipos diferentes de funções: convolução e agrupamento (BHADORIA et al., 2021). Na Figura 3, é apresentada a estrutura em camadas de uma rede neural profunda.

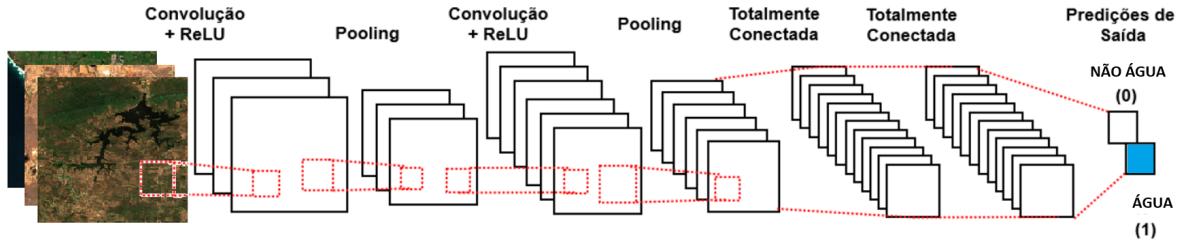
Figura 3: Estrutura de uma rede neural profunda simplificada.



Fonte: Farias (2023).

A arquitetura de uma CNN, de maneira geral, inclui três tipos principais de camadas: convolucionais, *pooling* e completamente conectadas (KANG; WANG, 2014). As camadas convolucionais têm a função de extraírem características e reduzir a dimensionalidade dos dados destinados à classificação. Nesse processo, as características são transferidas de uma camada para outra, onde cada neurônio na camada atual está conectado a uma área local receptiva na camada anterior. Dessa forma, as características são combinadas sequencialmente para a extração de características de mais alto nível (FERNANDES, 2013). Essas camadas são seguidas por camadas completamente conectadas, que assumem a responsabilidade pela classificação com base nas características extraídas nas camadas precedentes. A Figura 4 ilustra a arquitetura de uma CNN.

Figura 4: Estrutura de uma CNN.

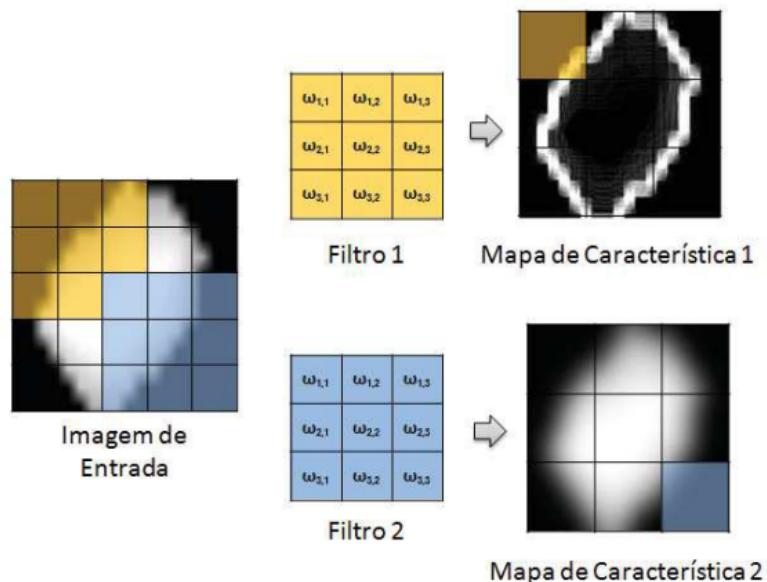


Fonte: Adaptado de Araújo et al. (2017).

2.3.1.1 Camada convolucionais

As camadas de convolução são compostas por filtros ajustáveis que são aplicados à imagem de entrada para produzir diversos mapas de características (LECUN et al., 2015). Esses filtros delimitam uma área pequena (por exemplo, 3×3 , 5×5 , 7×7 pixels), sendo cada neurônio conectado apenas aos neurônios nas proximidades da camada anterior. Os pesos dos filtros são compartilhados entre os neurônios, o que possibilita que os filtros aprendam padrões comuns em diferentes partes da imagem. Após o treinamento da rede, cada filtro é encarregado de detectar características específicas que podem ocorrer em qualquer lugar da imagem, independentemente da localização exata na entrada (HAFEMANN, 2014). A Figura 5 ilustra como ocorre a convolução em uma imagem.

Figura 5: Representação da Camada de Convolução.



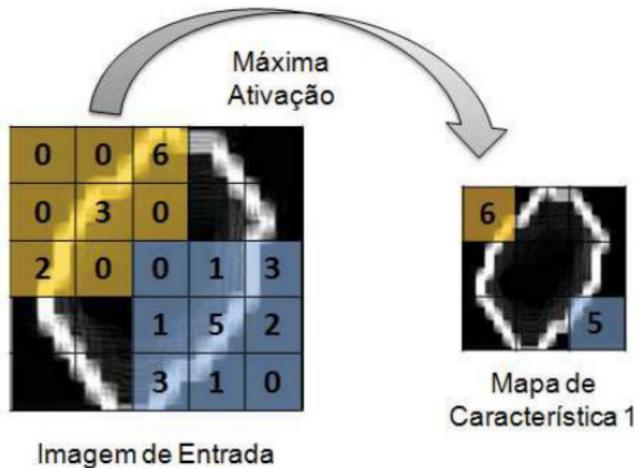
Fonte: Silva (2017).

2.3.1.2 Pooling

Após a camada de convolução, é utilizado a camada *pooling*. As camadas de *pooling*, de acordo com Hafemann (2014), são utilizadas para construir o mapa de recursos agrupando as informações advindas das camadas anteriores. Esta camada visa reduzir os dados de entrada. Com a redução dos dados de entrada, também há a redução do custo computacional. Além disso, a operação de *pooling* ajuda a evitar o *overfitting*, um fenômeno no qual a rede memoriza os dados de treinamento, dificultando sua capacidade de generalização para novos conjuntos de dados.

A Figura 6 apresenta o processo da camada de *pooling* do tipo máxima ativação, no qual apenas o pixel de maior intensidade no campo receptivo anterior é mantido, criando uma matriz de pixels com valores mais altos. Essa técnica descarta valores menos relevantes, tornando a rede mais robusta a pequenas mudanças e distorções. Outras formas de *pooling* incluem a média e a mediana.

Figura 6: Representação da Camada de *Pooling*.



Fonte: Silva (2017).

2.3.1.3 Camadas completamente conectadas

Após a conclusão das etapas de convolução e *pooling*, que visam extrair características da imagem, os pixels de todos os mapas de características da camada anterior são fornecidos como entrada às camadas completamente conectadas. Estas camadas são encarregadas da classificação dos padrões de entrada, de forma semelhante ao perceptron de múltiplas camadas (MLP, do inglês *Multilayer Perceptron*).

Na camada totalmente conectada, o sinal é propagado por meio de multiplicações ponto a ponto e da aplicação de uma função de ativação. A imagem de entrada é classificada com base nas características extraídas, permitindo à rede neural determinar a

probabilidade de pertencer a uma das classes previamente treinadas. O ajuste dos pesos do modelo é realizado por meio do processo de retropropagação do gradiente do erro (ABIRAMI; CHITRA, 2020).

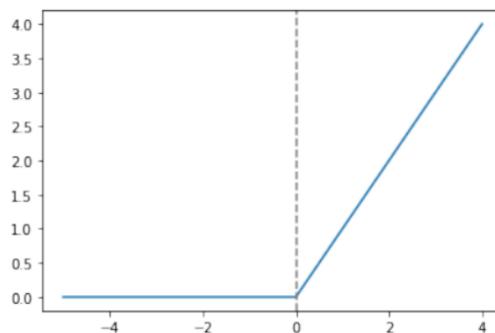
2.3.1.4 Funções de ativações

Na construção de modelos de redes neurais, as funções de ativação desempenham um papel crucial, introduzindo não linearidade e determinando quando um neurônio deve ser ativado com base na relevância da informação.

Uma função de ativação amplamente empregada é a ReLU (*Rectified Linear Unit*), que é frequentemente seguida por operações adicionais, como camadas de *pooling*, camadas totalmente conectadas e camadas de normalização. A retropropagação é uma técnica usada para distribuir erros e ajustar os pesos da rede (REN et al., 2021). A função ReLU gera valores na faixa de 0 a infinito, onde valores negativos retornam como 0 e valores positivos permanecem inalterados. Para ativar um neurônio, o valor de entrada deve ser maior que 0, tornando essa função esparsa e eficiente. A representação matemática da função ReLU é descrita pela Equação 1 e visualizada na Figura 7.

$$ReLU(x) = \max\{0, x\} \quad (1)$$

Figura 7: Função de ativação ReLU.

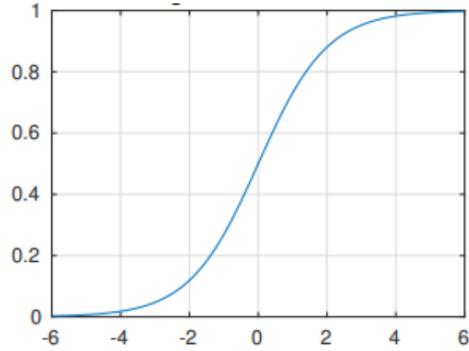


Fonte: Goldbarg (2021).

A função de ativação *sigmoid* é uma função de ativação não linear amplamente utilizada. Ela transforma um número real em um valor entre 0 e 1. Quando a entrada é grande, o resultado se aproxima de 1, enquanto para entradas grandes e negativas, o resultado se aproxima de zero. Isso possibilita a interpretação da intensidade de ativação dos neurônios, onde 0 indica nenhuma ativação e 1 representa uma ativação completa (ZHANG et al., 2021). A função *sigmoid* é definida conforme a Equação 2 e é ilustrada na Figura 8.

$$S(x) = \frac{1}{1 + e^{-x}} \quad (2)$$

Figura 8: Função de ativação *sigmoid*.



Fonte: Zhang et al. (2021).

2.3.1.5 Aumento de dados

O aumento de dados, conhecido como *data augmentation*, é uma estratégia que visa expandir o conjunto de dados de treinamento, por meio da geração artificial de novas amostras a partir dos dados já existentes. Embora seja amplamente utilizado em conjuntos de dados pequenos, essa técnica pode ser aplicada mesmo quando o conjunto de dados é extenso. Para criar novas instâncias de dados, são empregadas diversas técnicas, como translação, rotação, modificação de perspectiva, introdução de ruídos, achatamento, alongamento, entre outras, que são aplicadas às entradas durante a fase de treinamento. Além de aumentar o tamanho do conjunto de dados, o *data augmentation* também contribui para mitigar o *overfitting*.

2.3.1.6 Adam

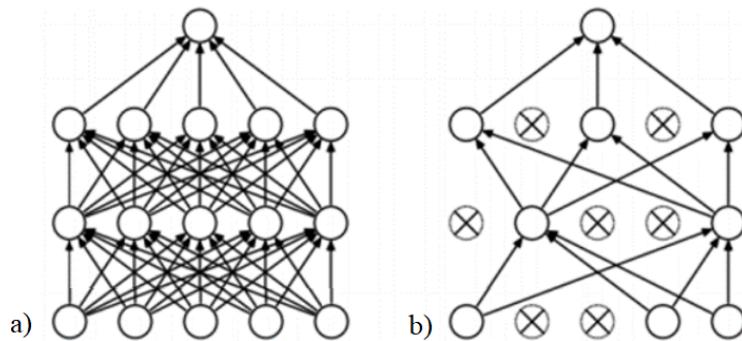
O otimizador Adam é uma técnica empregada em modelos de redes neurais com o objetivo de acelerar o processo de treinamento. Ele combina o método do gradiente descendente estocástico, com uma abordagem que adapta automaticamente a taxa de aprendizado, levando em consideração a velocidade e a direção em que os gradientes estão se alterando (KINGMA; BA, 2017).

2.3.1.7 Dropout

O *dropout* é uma abordagem de regularização empregada em redes neurais com o propósito de mitigar o *overfitting*. O mecanismo do *dropout* consiste em desativar, de

maneira aleatória, um conjunto de unidades de saída em uma camada durante o processo de treinamento. Isso induz a rede a adquirir representações mais diversificadas e diminui a ênfase em características particulares, resultando em uma ampliação da capacidade de generalização do modelo (SRIVASTAVA et al., 2014). A Figura 9 ilustra o efeito do *dropout* em uma rede neural.

Figura 9: Ilustração do efeito *dropout* em uma rede neural. a) Rede neuronal padrão com 2 camadas ocultas. b) Exemplo da aplicação do *dropout* na rede da esquerda.



Fonte: Srivastava et al. (2014).

2.3.1.8 *Flatten*

A camada de *flatten* é um componente comumente aplicado em CNNs e tem a finalidade de transformar a saída das camadas convolucionais em um vetor unidimensional. Essa conversão possibilita a transição da saída das camadas convolucionais para uma camada densa, permitindo que a rede neural aprenda padrões mais complexos e abstratos.

2.3.1.9 Aprendizado por Transferência

A aprendizagem por transferência é uma técnica de aprendizado profundo que envolve a reutilização do conhecimento adquirido em uma tarefa para a execução de outra (AFRIDI et al., 2018). Essa abordagem permite a utilização dos parâmetros de um modelo previamente treinado em um conjunto de dados como o *ImageNet*, que abrange mais de 1000 classes de imagens. Em outras palavras, modelos previamente treinados em conjuntos de dados podem ser aplicados a tarefas semelhantes de maneira mais eficiente e precisa, uma vez que podem aproveitar os pesos pré-treinados de um conjunto de dados muito mais amplo, resultando em um tempo de convergência mais curto.

2.4 Segmentação de Imagens

A segmentação de imagens é o processo de subdividir uma imagem em regiões com características semelhantes, que não se sobrepõem. Ela visa extrair regiões ou objetos de acordo com o objetivo desejado (ZHAO et al., 2021). Essa etapa desempenha um papel fundamental no processamento de imagens, pois uma segmentação eficaz simplifica a análise subsequente ao fornecer uma representação mais comprehensível e estruturada da imagem. A segmentação pode ser conduzida manualmente, analisando imagem por imagem, ou de maneira automática por meio de algoritmos.

Nos últimos anos, o uso de técnicas de aprendizado profundo tem se destacado na área de segmentação de imagens, com ênfase nas Redes Neurais Convolucionais (WANG et al., 2021). Um exemplo notável de aplicação dessas técnicas é a segmentação de corpos d'água em imagens de satélite. No estudo conduzido por Chen et al. (2018), uma arquitetura de CNN foi proposta para extrair corpos d'água em imagens de sensoriamento remoto de alta resolução. Os resultados demonstraram uma precisão significativamente superior em comparação com abordagens tradicionais, com uma precisão média de 99,14%.

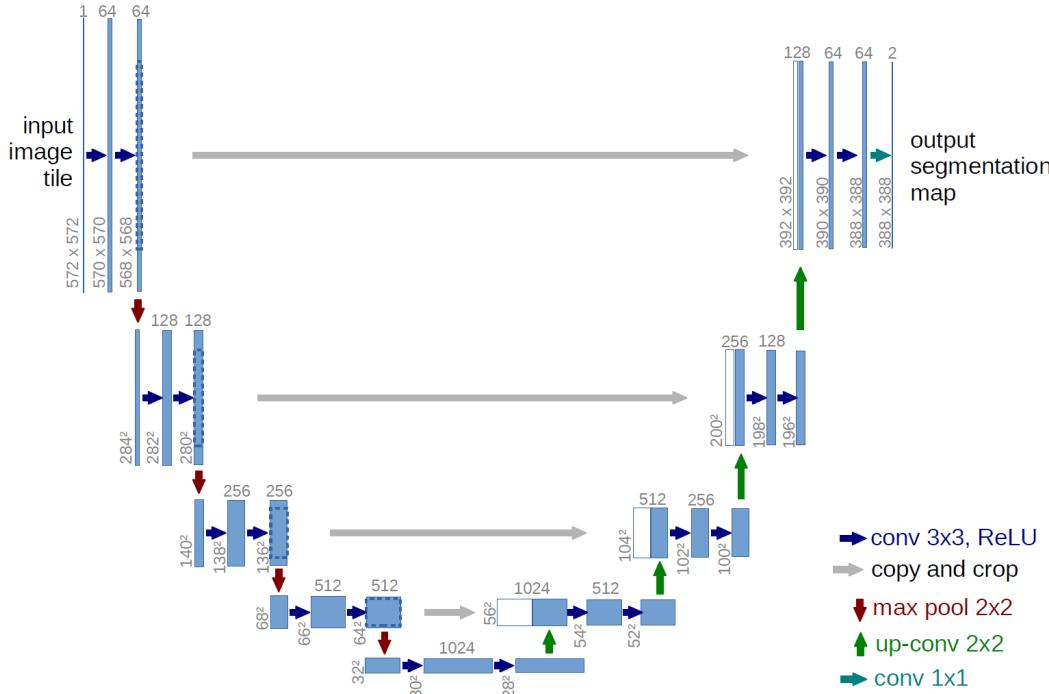
Outro exemplo do uso de CNN em imagens de satélite é apresentado por Miranda et al. (2021), onde uma CNN foi empregada para classificar o volume de água em represas no estado de São Paulo, Brasil, com base em imagens de sensoriamento remoto. Os resultados revelaram uma acurácia geral de 85,56% no modelo, com testes realizados nas represas de Atibainha e Jaguari do sistema de abastecimento de água Cantareira, destacando a viabilidade dessa abordagem para essa aplicação.

Uma arquitetura amplamente empregada na segmentação de imagens é a U-Net. Ela se tornou uma escolha comum para pesquisadores e profissionais no processamento de imagens, graças à sua eficácia e capacidade de combinar informações contextuais e detalhes locais na criação de máscaras precisas e extração de características relevantes.

2.4.1 U-Net

O modelo U-Net foi inicialmente apresentado por Ronneberger et al. (2015) para segmentação de imagens biomédicas. Desde então, diversos estudos têm explorado o potencial deste modelo em várias aplicações, como classificação de cobertura e uso do solo urbano (ZHANG et al., 2018), segmentação semântica de um espaço verde urbano (LIU et al., 2019), segmentação semântica de uma área de cultivo de pequenos agricultores (DU et al., 2019), mapeamento de tipos de floresta e perturbações na Mata Atlântica com imagens de alta resolução (WAGNER et al., 2019), segmentação semântica de espécies de árvores em ambiente urbano (TORRES et al., 2020), e classificação de cobertura do solo e detecção de objetos (ZHANG et al., 2020).

Figura 10: Representação da Arquitetura U-Net.



Fonte: Ronneberger et al. (2015).

A U-Net é um modelo específico de Rede Totalmente Convolucional (FCN - do inglês, *Fully Convolutional Network*), composto por um caminho de contração simétrica e um caminho expansivo. Esta arquitetura aprimora a precisão da segmentação ao combinar características de baixo nível, contendo informações espaciais detalhadas, com características de alto nível e informações semânticas. Essa abordagem demonstra eficácia em tarefas de segmentação de uma classe (ZHANG et al., 2018).

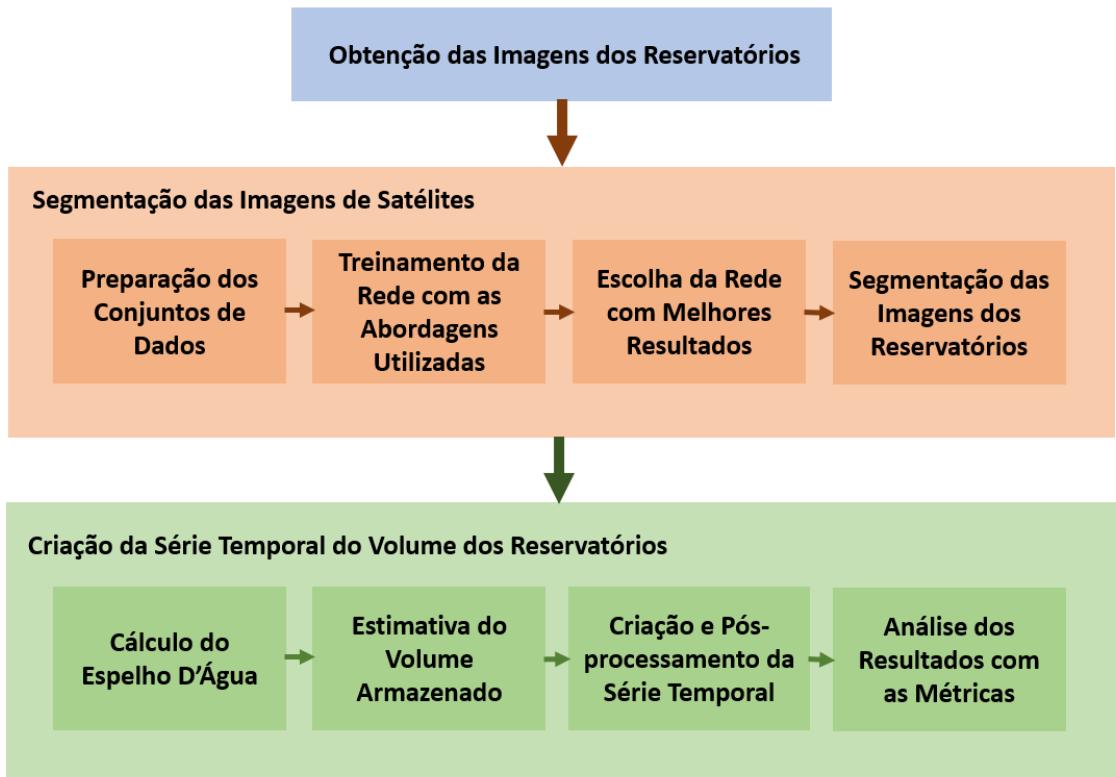
A arquitetura da U-Net é caracterizada por um padrão em forma de U (Figura 10), no qual cada bloco consiste em duas camadas de convolução seguidas por uma camada de *pooling*. Esses blocos são organizados em uma estrutura em que cada nível da escada conecta o caminho de *downsampling* (redução da amostragem) ao caminho de *upsampling* (aumento da amostragem). Essas conexões entre os caminhos ajudam a preservar informações contextuais importantes ao longo da rede (SUDRE et al., 2017).

Essa rede pode ser treinada de ponta a ponta a partir de um pequeno conjunto de imagens, onde a U-Net simplesmente concatena os mapas de características do codificador para mapear características do decodificador em todas as etapas, formando uma estrutura semelhante a uma escada. Através das conexões de concatenação, essa arquitetura possibilita que o decodificador em cada etapa aprenda características relevantes que podem ser perdidas durante o processo de agrupamento no codificador. No presente estudo, a U-Net foi empregada para realizar a segmentação de corpos hídricos em imagens de satélite.

3 MATERIAIS E MÉTODOS

O capítulo de Materiais e Métodos detalha o procedimento metodológico desenvolvido para a realização deste estudo, que foi dividido em duas etapas. A primeira etapa compreende a segmentação de corpos d’água nas imagens de satélite. Inicialmente, foi desenvolvida a arquitetura da rede utilizada na construção do modelo de segmentação. Para avaliar a eficácia da rede, foram conduzidos quatro testes diferentes durante o treinamento da U-Net. Na segunda etapa do trabalho, as imagens segmentadas na primeira etapa foram utilizadas para estimar a área superficial dos reservatórios hídricos. Com base na área superficial obtida, foi determinado o volume correspondente. A Figura 11 apresenta as etapas para aplicação da metodologia aplicada ao estudo.

Figura 11: Metodologia adotada na pesquisa.



Fonte: Elaborado pela autora.

3.1 Área de Estudo

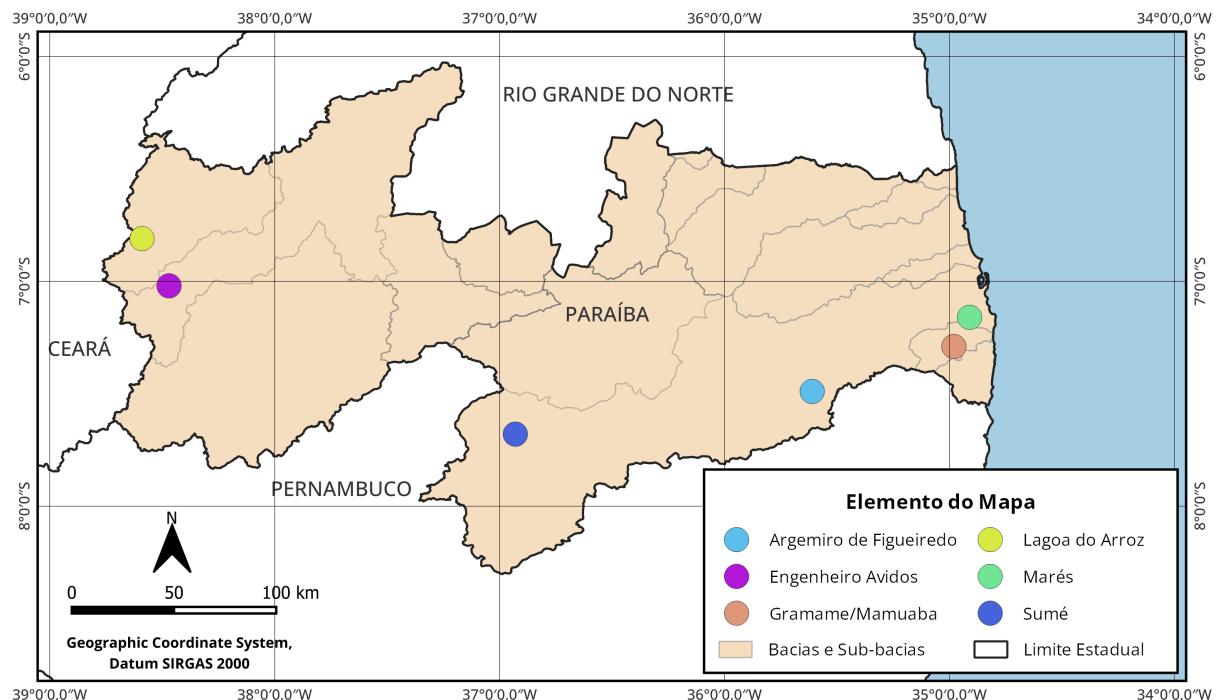
A área de estudo abrange alguns dos reservatórios localizados nas principais regiões hidrográficas do estado da Paraíba. Para atender aos objetivos deste estudo, foram selecionados seis reservatórios distribuídos em diversas regiões do estado, levando em consideração suas características distintas.

Os critérios utilizados para a seleção dos reservatórios foram a capacidade hídrica e a localização geográfica. Os reservatórios foram escolhidos com base em sua capacidade de

armazenamento de água, visando representar uma variedade de tamanhos, desde pequenos até grandes volumes de armazenamento. Além disso, buscou-se representar diferentes regiões do estado da Paraíba, incluindo áreas costeiras, regiões de semiárido e outras áreas geograficamente distintas.

Esse reservatórios incluem o Engenheiro Ávidos, Argemiro de Figueiredo, Lagoa do Arroz, Gramame-Mamuaba, Sumé e Marés. A Figura 12 ilustra o mapa do estado da Paraíba com a localização dos seis reservatórios selecionados.

Figura 12: Mapa do estado da Paraíba com a localização dos seis reservatórios escolhidos.



Fonte: Elaborado pela autora.

3.1.1 Reservatório Engenheiro Ávidos

O Engenheiro Ávidos (Figura 13) está localizado no município de Cajazeiras. Sua construção foi iniciada em 1932 pelo engenheiro Moacir Ávidos e concluída em 1936 pelo engenheiro Sílvio Aderne (DNOCS, 2003). Sua finalidade é abastecer Cajazeiras e Nazarezinho, dos distritos Engenheiro Ávidos e Gravatá, bem como regularizar a vazão do Rio Piranhas. Suas águas são utilizadas para o abastecimento humano, dessedentação animal, irrigação e indústria (ANA, 2016). O município de Cajazeiras, onde está situado, apresenta destaque no sertão como centro de educação e cultura. A Tabela 4 apresenta as principais características do reservatório Engenheiro Ávidos.

No contexto climatológico, o reservatório está situado no que é conhecido como “Polígono das Secas”, caracterizado por um clima semiárido quente e seco. Durante o

Figura 13: Reservatório Engenheiro Ávidos em 22 de junho de 2020.



Tabela 4: Características do reservatório Engenheiro Ávidos.

Rio Represado	Rio Piranhas
Localização	Cajazeiras-PB
Bacia Hidrográfica	Alto Piranhas
Volume Máximo	255.000.000 m^3
Área Alagada Máxima	27.884.911 m^2

Fonte: AESA (2023).

dia, as temperaturas são altas, enquanto tendem a diminuir durante a noite, com variações anuais oscilando entre 23 e 30º C, havendo ocasionalmente picos mais elevados, especialmente durante a estação seca. A precipitação é escassa e irregular, com uma média anual de 880,6 mm, variando entre mínimos de 227,1 mm e máximos de 1961,0 mm. De forma geral, o clima é marcado por apenas duas estações distintas: a estação seca, que corresponde ao verão, alcançando seu auge de setembro a dezembro; e a estação chuvosa, conhecida localmente como inverno, que se limita a um período de 3 a 4 meses, geralmente entre fevereiro e abril, a cada ano (COSTA, 2010).

3.1.2 Reservatório Argemiro de Figueiredo

O reservatório Argemiro de Figueiredo (Figura 14), popularmente conhecido como Acauã, está localizado no Agreste paraibano, entre os municípios de Itatuba e Natuba. Ele represa as águas do Rio Paraíba no exutório do seu médio curso. Classificado como o quarta maior reservatório em capacidade de armazenamento de água no estado da Paraíba, possui uma capacidade máxima de acumulação de 253 milhões de metros cúbicos. O impacto significativo da construção da barragem Argemiro de Figueiredo se reflete em toda a região, afetando diversos aspectos, inclusive a otimização do abastecimento de água

das comunidades situadas a jusante, bem como o uso da água em atividades econômicas realizadas pela população local. Isso possibilita a sustentabilidade econômica, promovendo a pesca direta no reservatório e no curso perene do rio (CORREIA et al., 2007). A Tabela 5 apresenta as principais características do reservatório Argemiro de Figueiredo.

Figura 14: Reservatório Argemiro de Figueiredo em 25 de agosto de 2020.



Tabela 5: Características do reservatório Argemiro de Figueiredo.

Rio Represado	Rio Paraíba
Localização	Itatuba-PB
Bacia Hidrográfica	Paraíba
Volume Máximo	253.142.247 m^3
Área Alagada Máxima	17.247.867 m^2

Fonte: AESA (2023).

Em termos climatológicos, a área onde o reservatório está localizado possui um clima Tropical Semiárido, caracterizado por chuvas de verão. Essas chuvas geralmente começam em novembro e terminam entre abril e junho, resultando em uma precipitação pluviométrica notavelmente irregular. As médias anuais e mensais de precipitação giram em torno de 431,8 mm e 60 mm, respectivamente (BELTRÃO et al., 2005).

3.1.3 Reservatório Lagoa do Arroz

Assim como o Engenheiro Ávidos, o reservatório Lagoa do Arroz (Figura 15) é localizado no município de Cajazeiras. Tem capacidade de armazenamento de 80 milhões de metros cúbicos de água (AES, 2023). A barragem situa-se no Vale do Riacho Cacaré, afluente pela margem direita do Rio do Peixe, e abastece a zona norte da cidade, além das cidades de São João do Rio do Peixe, Bom Jesus e Santa Helena, além de alimentar

vários projetos de irrigação na região e suas águas servirem de lazer, onde são encontrados alguns balneários que recebem turistas principalmente nos finais de semanas (BRAGA, 2016). A Tabela 16 apresenta as principais características do reservatório Lagoa do Arroz.

Figura 15: Reservatório Lagoa do Arroz em 7 de julho de 2020.



Tabela 6: Características do reservatório Lagoa do Arroz.

Rio Represado	Riacho Cacaré
Localização	Cajazeiras-PB
Bacia Hidrográfica	Peixe
Volume Máximo	80.220.750 m^3
Área Alagada Máxima	12.284.000 m^2

Fonte: AESA (2023).

Por estar localizado na mesma região do reservatório Engenheiro Ávidos, este reservatório compartilha as mesmas características climatológicas. Está situado em uma área de clima semiárido quente e seco, caracterizada por temperaturas elevadas e baixa precipitação. As estações são distintas entre seca (verão) e chuvosa (inverno), com chuvas irregulares (COSTA, 2010).

3.1.4 Reservatório Gramame-Mamuaba

O Reservatório de Gramame-Mamuaba (Figura 16) fica localizado na cidade de Alhandra, região metropolitana da capital João Pessoa. Composto por duas barragens conectadas por um canal de 750 metros, este reservatório abrange os rios Gramame e Mamuaba, tendo uma capacidade total de aproximadamente 56,94 milhões de metros cúbicos (AES, 2023). Silva et al. (2016) ressaltam a importância desse manancial, que representa a principal fonte de água para o abastecimento de grande parte da população da região metropolitana de João Pessoa, contribuindo com cerca de 70% do fornecimento de água pela Companhia de Água e Esgotos da Paraíba (CAGEPA). O reservatório de

Gramame-Mamuaba é utilizado para diversos fins, incluindo abastecimento humano, irrigação, piscicultura, pesca recreativa e lazer das comunidades vizinhas.(SILVA, 2018). A Tabela 7 apresenta as principais características do reservatório Gramame-Mamuaba.

Figura 16: Reservatório Gramame-Mamuaba em 26 de junho de 2021.

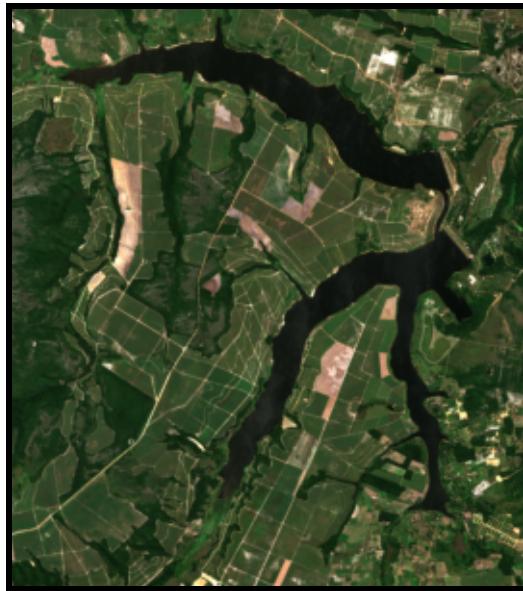


Tabela 7: Características do reservatório Gramame-Mamuaba.

Rio Represado	Rios Gramame e Mamuaba
Localização	Alhandra-PB
Bacia Hidrográfica	Gramame-Mamuaba
Volume Máximo	56.937.000 m^3
Área Alagada Máxima	8.552.990 m^2

Fonte: AESA (2023).

O reservatório Gramame-Mamuaba está localizado na mesorregião da Zona da Mata, que possui um clima caracterizado como Tropical quente-úmido. Nessa região, as estações de primavera e verão são menos chuvosas, com chuvas abundantes ocorrendo de maio a agosto, com uma média anual de precipitação entre 1200 e 1800 mm. A temperatura média é de 26°C, com as mínimas variando em torno de 23°C nos meses de julho e agosto. A amplitude térmica anual é de 5°C, e a umidade relativa do ar é cerca de 80% (FREITAS, 2012).

3.1.5 Reservatório Sumé

O Reservatório de Sumé (Figura 17) está localizado no município de mesmo nome. Ele foi construído pelo Departamento Nacional de Obras Contra as Secas (DNOCS) durante o período de 1957 a 1962. Possui uma capacidade máxima de armazenamento de

44,8 milhões de metros cúbicos e uma área de superfície correspondente a 8,5 milhões de metros quadrados, de acordo com informações fornecidas por DNOCS (2003). O reservatório é utilizado pelos concessionários dos terrenos para atividades agrícolas, pesca tradicional e criação de animais, conforme indicado por Cantalice (2010). A Tabela 8 apresenta as principais características do reservatório Sumé.

Figura 17: Reservatório Sumé em 4 de julho de 2020.



Tabela 8: Características do reservatório Sumé.

Rio Represado	Rio Sucuru
Localização	Sumé-PB
Bacia Hidrográfica	Paraíba
Volume Máximo	44.864.100 m^3
Área Alagada Máxima	8.518.250 m^2

Fonte: AESA (2023).

Do ponto de vista climatológico, o reservatório Sumé está situado no que é conhecido como "Polígono das Secas", caracterizado por um clima semiárido quente e seco. As temperaturas são elevadas durante o dia, diminuindo à noite, com variações anuais entre 26 e 31°C e picos mais altos durante a estação seca. A precipitação pluviométrica é baixa e irregular, com uma média anual de aproximadamente 871,1 mm, variando entre mínimas de 339,6 mm e máximas de 1521,8 mm por ano (SUMÉ, 2014).

3.1.6 Reservatório Marés

O Reservatório Marés (Figura 18) está situado a oeste da cidade de João Pessoa. Sua construção teve início em 1948, durante a gestão do governador Osvaldo Trigueiro, e foi concluída em 1952, sob a administração de José Américo de Almeida. O projeto foi

concebido para complementar o sistema de abastecimento de Buraquinho, que atendia à crescente população da capital por meio de poços. O reservatório tem uma capacidade de aproximadamente 2 milhões de metros cúbicos e, atualmente, fornece água para cerca de 30% da população de João Pessoa, além de atender a alguns bairros de Santa Rita e Bayeux. Suas principais funções incluem o abastecimento de água para consumo humano, atividades de lazer, pesca artesanal e fornecimento de água para animais (SILVA, 2018). A Tabela 9 apresenta as principais características do reservatório Marés.

Figura 18: Reservatório Marés em 04 de dezembro de 2019.



Tabela 9: Características do reservatório Marés.

Rio Represado	Rio Marés
Localização	João Pessoa-PB
Bacia Hidrográfica	Paraíba
Volume Máximo	$2.136.637\ m^3$
Área Alagada Máxima	$394.343\ m^2$

Fonte: AESA (2023).

O Reservatório de Marés, localizado na cidade de João Pessoa, possui características climatológicas típicas da região litorânea nordestina. O clima é classificado como tropical úmido, com temperaturas elevadas ao longo do ano, geralmente variando entre 25°C e 30°C. A umidade relativa do ar é relativamente alta, especialmente durante os meses mais quentes, proporcionando uma sensação de calor intenso. As chuvas são mais frequentes durante os meses de abril a julho, coincidindo com a estação chuvosa. No entanto, mesmo nos meses mais secos, a precipitação ainda pode ocorrer devido à influência dos ventos úmidos vindos do oceano (SOBREIRA, 2010).

3.1.7 Obtenção das Imagens

As imagens dos reservatórios paraibanos foram obtidas através do *Google Earth Engine* (GEE). O GEE é uma plataforma baseada em nuvem que oferece uma vasta coleção de imagens de satélite e conjuntos de dados geoespaciais de acesso público, com capacidades de análise em escala global, tornando-os acessíveis para cientistas, pesquisadores e desenvolvedores que desejam estudar a superfície terrestre (INC, 2022).

Para o monitoramento das superfícies aquáticas, foram adquiridas imagens dos seis reservatórios selecionados no formato *TIFF*, com as bandas B2, B3, B4, B8, B11 e B12, totalizando seis bandas da missão *Sentinel-2 L2A*. Essas seis bandas coincidem com aquelas utilizadas nas imagens empregadas para o treinamento da rede, conforme será detalhado na Seção 3.2.1. As imagens utilizadas no estudo possuem uma resolução espacial de 10 metros, sendo que cada um dos reservatórios selecionados apresenta dimensões distintas.

O conjunto de imagens abrange o período de dezembro de 2018 a setembro de 2023. Embora a missão Sentinel-2 L2A disponha de imagens mais antigas do que o período selecionado, no momento em que foram adquiridas para este estudo pelo GEE, elas estavam disponíveis apenas a partir do final de 2018. Assim, optou-se por utilizar o período de 2018 a 2023 para garantir a consistência dos dados e a disponibilidade de imagens para análise. Muitas das imagens adquiridas apresentavam uma cobertura significativa de nuvens, o que dificultava a previsão da superfície da água usando modelos de aprendizado profundo. Para superar esse problema, implementou-se um filtro que selecionou apenas as cenas com uma cobertura mínima de nuvens, excluindo aquelas em que mais de 20% da área da superfície da água dos corpos hídricos estava coberta por nuvens. Como resultado, foram obtidas as seguintes quantidades de imagens para cada reservatório: 158 imagens para o Reservatório Engenheiro Ávidos, 65 imagens para o Reservatório Argemiro de Figueiredo, 165 imagens para o Reservatório Lagoa do Arroz, 68 imagens para o Reservatório Gramame/Mamuaba, 166 imagens para o Reservatório Sumé e 127 imagens para o Reservatório Marés.

3.2 Segmentação das Imagens de Satélites

Nesta seção, descreveremos as etapas envolvidas na criação de um modelo de aprendizado profundo para a segmentação de corpos d'água em imagens de satélite. Inicialmente, foi selecionado o conjunto de dados utilizado no treinamento do modelo. Em seguida, desenvolvemos a arquitetura da rede neural utilizada na construção do modelo de segmentação, a qual é fundamental para extrair a área de superfície hídrica a partir das imagens de satélite. Esse processo incluiu a definição das características do modelo e a escolha do conjunto de dados para o treinamento. Utilizamos diversas abordagens e

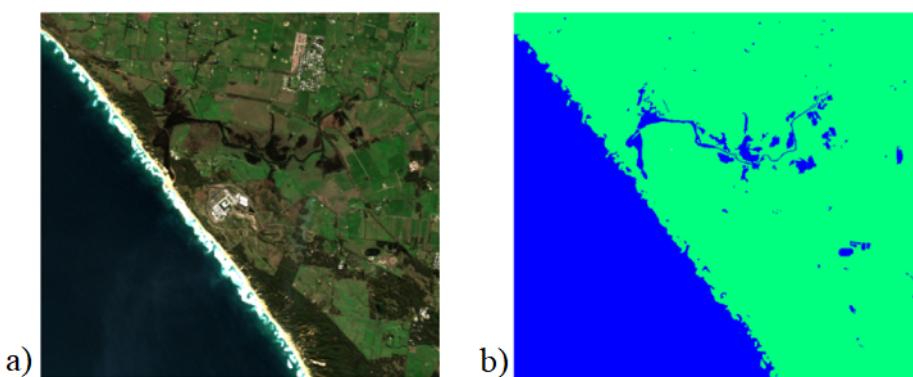
técnicas, visando aprimorar o desempenho e a precisão na segmentação das áreas de água, incorporando estratégias específicas para otimizar a precisão do processo de segmentação.

3.2.1 Conjunto de Dados da Rede

O conjunto de dados utilizado para o treinamento da rede foi o *Earth Surface Water Knowledge Base* (ESWKB) (LUO et al., 2021). Ele é composto por 95 imagens no formato TIFF coletadas do *Sentinel-2 Multispectral Instrument* (MSI), com correção atmosférica em todo o mundo e ao longo de todas as estações do ano.

O conjunto é formado por vários tipos de corpos d'água e não d'água, o que suporta um aprendizado completo e de alta qualidade das características das águas superficiais. As imagens do conjunto são compostas por seis bandas ao total: quatro bandas de resolução de 10 m (Blue, Green, Red, NIR) e duas bandas de resolução de 20 m que abrangem as partes do espectro visível ao infravermelho (SWIR). Das 13 bandas que o satélite Sentinel-2 fornece, foram removidas as bandas espectrais de resolução mais baixa. Cada imagem é acompanhada de sua respectiva máscara. Elas funcionam como etiquetas que atribuem a cada pixel uma categoria específica, com o propósito de distinguir entre diferentes classes de objetos ou características na imagem. No contexto deste estudo, as máscaras são utilizadas para identificar e classificar os pixels que correspondem a corpos d'água (classe 1) e aqueles que representam outras características, como áreas terrestres ou nuvens (classe 0). A Figura 19 apresenta um exemplo de imagem do conjunto de dados juntamente com a máscara correspondente.

Figura 19: Exemplo de uma imagem do conjunto de dados utilizado. a) Visualização das bandas B2, B3 e B4 de uma imagem do conjunto de dados. b) A máscara correspondente.



Fonte: Elaborado pela autora.

Para o treinamento da rede, foram utilizadas imagens de 128×128 pixels. Dessa forma, foi realizado um pré-processamento de dados transformando as imagens brutas em um formato desejado para análise. Para alcançar as dimensões desejadas das imagens

para o treinamento da rede, foram realizadas operações de preenchimento (*padding*) para ajustar todas as imagens ao tamanho adequado para corte. Em seguida, foi efetuado o corte para garantir que todas as imagens possuíssem 128×128 pixels. Essas etapas resultaram na geração de 3800 imagens com as dimensões especificadas. A Figura 20 ilustra o processo de pré-processamento das imagens do conjunto de dados.

Figura 20: Pré-processamento das imagens do conjunto de dados. a) Imagem original. b) Imagem com o *padding*. c) Imagem após o processo de corte.



Fonte: Elaborado pela autora.

Além disso, foi utilizada a técnica de aumento de dados (*data augmentation*). Esta técnica é utilizada com o intuito de aprimorar a capacidade do modelo em generalizar para novos exemplos e evitar problemas de *overfitting*, mesmo quando a quantidade de imagens é limitada. Para expandir o conjunto de dados, recorreu-se à biblioteca disponível em *Python* denominada *Albumentations*. Essa biblioteca possibilita a aplicação de uma série de transformações aleatórias em imagens e máscaras, resultando na geração de novas imagens e máscaras a partir das originais. Entre as transformações utilizadas, incluem-se: rotação, espelhamento horizontal e vertical, além de ajustes aleatórios de brilho e contraste nas imagens iniciais.

Esse processo de aumento de dados resultou em um conjunto de dados expandido, totalizando 7.600 imagens com máscaras correspondentes. Portanto, foram criados dois conjuntos de dados: um com 3.800 imagens, que passaram pelo processo de pré-processamento, e outro com 7.600 imagens após a aplicação de estratégias de aumento de dados. A Figura 21 resume o processo de formação dos dois conjuntos de dados. Ambos os conjuntos de dados foram utilizados no teste da rede desenvolvida para este estudo, permitindo uma avaliação mais robusta de seu desempenho.

3.2.2 Arquitetura da Rede

A rede implementada neste estudo foi baseada na U-Net. A construção da rede foi realizada utilizando a biblioteca *Keras* versão 2.12, integrada com o *framework TensorFlow* 2.12. Ambas as bibliotecas são amplamente utilizadas para desenvolver modelos

Figura 21: Formação dos conjuntos de dados.



Fonte: Elaborado pela autora.

de aprendizado profundo e possuem uma comunidade ativa de desenvolvedores. Além disso, a implementação da rede foi feita em *Python* 3.10, uma linguagem de programação popular para tarefas de aprendizado de máquina e visão computacional.

Uma das principais modificações realizadas em relação ao modelo original da U-Net foi a redução pela metade da profundidade das camadas em cada etapa da rede. Essa redução foi efetuada com o propósito de otimizar a relação entre a profundidade da rede e a quantidade de dados disponíveis para treinamento. Em redes profundas, treinadas com um conjunto de dados limitado, pode ocorrer *overfitting*, ou seja, a rede se ajusta excessivamente aos dados de treinamento e não consegue generalizar bem para novos dados. Além disso, essa redução de profundidade contribui para a diminuição do tempo de processamento.

Outra modificação significativa foi a alteração do preenchimento (*padding*) das camadas de convolução para *same*. Essa mudança garante que nenhum pixel seja removido nos limites das imagens durante o processo de convolução, mantendo as dimensões de saída da rede iguais às dimensões de entrada. Isso facilita a correspondência entre as camadas e é especialmente relevante para imagens de entrada de 128x128 pixels.

Em todos os blocos de convolução da rede neural, foi implementada uma técnica conhecida como *dropout*. Essa técnica consiste em desligar aleatoriamente um determinado percentual de unidades de neurônios durante o treinamento da rede, o que ajuda a prevenir o sobreajuste (ou *overfitting*). Isso significa que, entre cada dois processos de convolução, uma camada de *dropout* foi adicionada para regular a complexidade da rede e melhorar sua capacidade de generalização.

Na última camada da rede neural, foi utilizada a função de ativação não linear *sigmoid*. Essa função transforma a saída da rede em valores contínuos entre 0 e 1, representando a probabilidade de um pixel pertencer à classe de interesse. Nesse contexto, uma probabilidade superior a um limiar (geralmente 50%) indica que o pixel pertence à classe de interesse, enquanto os pixels cuja probabilidade é inferior a esse limiar são

considerados como pertencentes à classe de fundo, ou seja, não representam os corpos d'água na imagem.

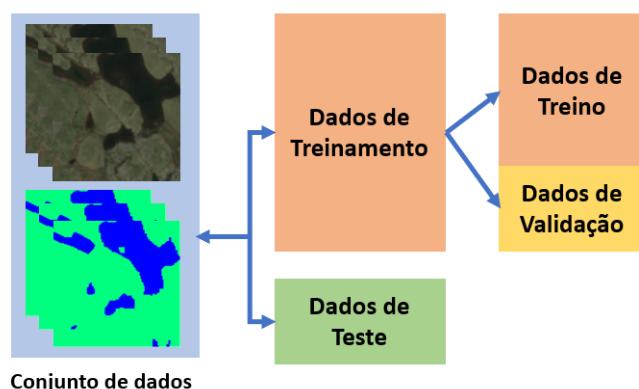
Essas modificações foram implementadas com o objetivo de aprimorar o desempenho da rede, torná-la mais eficiente em termos de processamento computacional e capaz de generalizar melhor para novos dados

3.2.3 Método do Treino da Rede

A abordagem principal adotada para o treinamento da rede consistiu na inicialização do treinamento com pesos do modelo inicializados de forma aleatória. Os dados de treinamento foram pré-processados e transformados em matrizes para serem utilizados no treinamento. Essas matrizes foram agrupadas em tensores, seguindo as configurações do *framework TensorFlow*. Os tensores resultantes possuíam dimensões (N, H, W, B), onde, N representa a quantidade de dados de treinamento, H e W representam as dimensões da imagem em comprimento e largura, respectivamente, e o B corresponde ao número de canais das matrizes, que, no caso de imagens, equivale às diferentes bandas espectrais.

Para avaliar o desempenho do modelo e garantir sua capacidade de generalização, o conjunto de dados foi inicialmente dividido em 10% para teste e 90% para treinamento e validação, respectivamente através do método *train_test_split* (biblioteca *Scikit-learn*). A divisão do conjunto de dados para o treinamento do modelo segue na Figura 22.

Figura 22: Divisão do conjunto de dados para o treinamento do modelo.



Fonte: Elaborado pela autora.

O treinamento foi realizado usando a técnica de validação cruzada (*cross-validation*), um método importante para avaliar o desempenho do modelo em vários conjuntos de dados e evitar o *overfitting*. A forma básica da validação cruzada é a *k-fold*, na qual os dados são divididos em k grupos de tamanho igual ou aproximado. Durante k iterações de treinamento e validação, um conjunto diferente é reservado para validação, enquanto as $k-1$ conjuntos restantes são utilizados para treinamento (REFAEILZADEH et al., 2009).

Durante o treinamento, o modelo é avaliado usando o conjunto de validação. O conjunto de treinamento foi dividido em 5 *folds*, em que cada *fold* é utilizado uma vez como conjunto de validação, enquanto os demais *folds* são utilizados como conjunto de treinamento. Isso implica que cerca de 20% do conjunto de treinamento é utilizado como conjunto de validação em cada iteração do *loop*.

Após cada ciclo de validação cruzada com $k = 5$ iterações, as métricas de desempenho, como acurácia, IoU, *Dice*, precisão, *recall* e pontuação F1, são registradas com base no conjunto de teste. As médias e desvio padrão dessas medidas foram então calculados, permitindo a avaliação da capacidade de generalização do modelo, ou seja, sua eficácia em lidar com dados novos e desconhecidos. Essas métricas de avaliação são empregadas para comparar as previsões do modelo com os dados de referência e avaliar seu desempenho geral.

Na Tabela 10, são apresentados os hiperparâmetros utilizados durante o treinamento e caracterização da rede. Esses hiperparâmetros foram definidos com base em práticas recomendadas e experimentos para alcançar um bom desempenho na tarefa de segmentação.

Tabela 10: Valores dos hiperparâmetros utilizados no treinamento do modelo de classificação.

Hiperparâmetros de Treino	Valores
Épocas	30
Tamanho do Lote	32
Função de Perda	BinaryCrossEntropy
Optimizador	Adam
Dropout	10%
Inicializador dos Pesos	He normal
Tamanho das Imagens	(128 × 128)
Função de ativação	ReLU
Dimensões do filtro	(3 × 3)

Fonte: Elaborado pela autora.

3.2.4 Abordagens Utilizadas

Para aprimorar o desempenho da segmentação semântica de água em imagens de satélite, foram exploradas diferentes abordagens que visavam melhorar a precisão e a capacidade de generalização do modelo.

Inicialmente, no Teste 1, foram realizados os testes no banco de dados sem a aplicação de abordagens especiais. Nessa etapa, a arquitetura do modelo U-Net foi empregada, seguindo a configuração previamente definida, para validar a capacidade do modelo

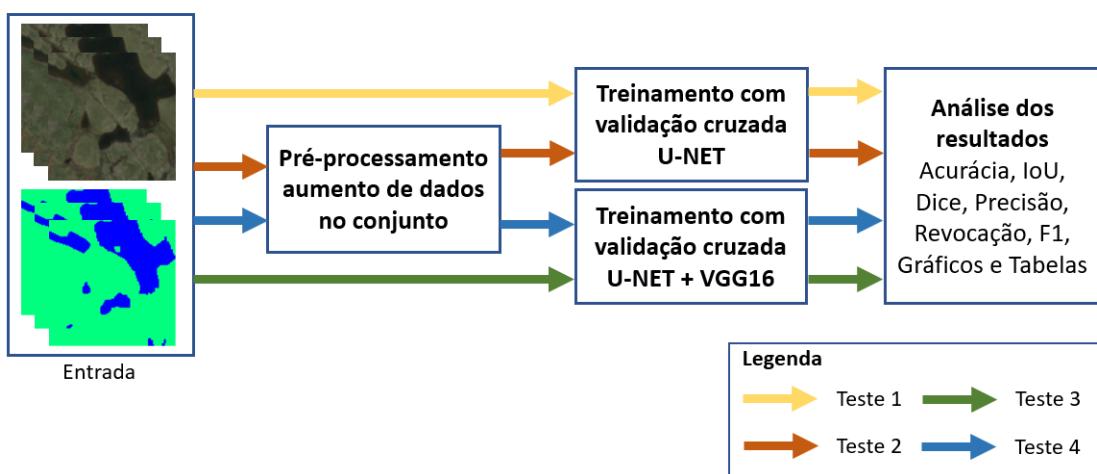
em realizar a segmentação semântica da água em imagens de satélite. Os resultados desses testes iniciais serviram como ponto de partida. Visando melhorar o desempenho, foi aplicada a abordagem de aumento de dados no Teste 2, duplicando o número de imagens disponíveis no banco de dados.

No Teste 3, a ênfase foi em obter um modelo mais generalizado através da transferência de aprendizado, incorporando o modelo VGG16 à rede U-Net. A estrutura da U-Net foi adaptada para incluir o VGG16 como parte do caminho de contração. O VGG16, carregada sem suas camadas superiores, teve suas camadas congeladas para preservar os pesos pré-treinados no conjunto de dados ImageNet. As camadas da U-Net foram adaptadas para incorporar as características do VGG16. Essencialmente, a arquitetura da U-Net foi estendida para aproveitar as representações complexas aprendidas pelo VGG16 no ImageNet, visando aprimorar a capacidade da U-Net na segmentação de corpos d'água em imagens multiespectrais.

O Teste 4 buscou integrar os modelos dos Testes 2 e 3 para uma abordagem mais abrangente. Essas diferentes estratégias foram aplicadas para explorar maneiras de melhorar o desempenho do modelo de segmentação em imagens de satélite, garantindo resultados mais precisos na identificação de áreas de superfície de água. Cada abordagem representou uma etapa no processo de aprimoramento do modelo, contribuindo para o progresso em direção a um modelo final mais robusto e preciso.

A Figura 23 apresenta os passos necessários para o treinamento do modelo obtido nas quatro abordagens diferentes. Cada teste foi identificado com uma seta de cor distinta: seta amarela para o Teste 1, seta vermelha para o Teste 2, seta verde para o Teste 3 e seta azul para o Teste 4.

Figura 23: Passos para obter o modelo em cada teste.



Fonte: Elaborado pela autora.

3.2.5 Métricas de Avaliação

Para avaliar o desempenho dos modelos desenvolvidos na segmentação de áreas de superfície de água em imagens de satélite, foram utilizadas várias métricas específicas. As métricas de avaliação incluíram acurácia, Intersecção sobre União (*Intersection-Over-Union — IoU*) também conhecida como Índice de Jaccard, coeficiente de similaridade de dados (*Dice Coefficient*), precisão, revocação e pontuação F1.

Na segmentação, são utilizados os valores de Verdadeiro Positivo (VP), Verdadeiro Negativo (VN), Falso Positivo (FP) e Falso Negativo (FN) para calcular métricas que avaliam a qualidade dos resultados. Eses valores são atribuídos a cada pixel da imagem. Durante o processo de segmentação, as classes positivas e negativas correspondem às regiões de água e do fundo, respectivamente. O cálculo dessas métricas permite avaliar o desempenho do modelo em relação à sua capacidade de detectar as áreas de interesse.

3.2.5.1 Acurácia

A acurácia mede a fração de pixels corretamente classificados e é calculada como a soma de verdadeiros positivos e verdadeiros negativos, dividida pelo número total de pixels. A Equação 3 define o cálculo da métrica de acurácia.

$$Acurácia = \frac{VP + VN}{VP + VN + FP + FN} \quad (3)$$

3.2.5.2 Índice de Jaccard (IoU)

O IoU é uma das métricas mais comuns na segmentação semântica, medindo a área de sobreposição entre a segmentação prevista e a verdade terrestre, dividida pela área de união entre essas duas segmentações. O IoU varia de 0 a 1 (0-100%), onde 0 significa nenhuma sobreposição e 1 significa que as segmentações estão perfeitamente sobrepostas (TIU, 2019).

Essa medida verifica o quanto a máscara de saída é semelhante à máscara correta. Matematicamente, o IoU entre dois conjuntos A e B é dado pela Equação 4.

$$J(A, B) = \frac{|A \cap B|}{|A \cup B|} \quad (4)$$

3.2.5.3 Coeficiente *Dice*

O coeficiente *Dice* é um método semelhante ao IoU para validar imagens de segmentação geradas por inteligência artificial. Ele é calculado como o dobro da área de sobreposição dividido pela soma das áreas da máscara prevista e da máscara verdadeira. Quanto mais próximo de 1, melhor o desempenho. Considera-se menos sensível às diferenças entre os elementos dos conjuntos do que o IoU, indicando que pequenas mudanças nos conjuntos podem ter um impacto menor no valor do coeficiente *Dice*. A expressão matemática para o coeficiente *Dice* é dada pela Equação 5.

$$Dice = \frac{2 \times |A \cap B|}{|A| + |B|} \quad (5)$$

3.2.5.4 Precisão e Revocação

Precisão e revocação medem a capacidade do modelo de segmentar corretamente os pixels da classe de interesse (verdadeiros positivos), em relação a todos os pixels segmentados como pertencentes a essa classe (verdadeiros positivos e falsos positivos). A precisão é a proporção de verdadeiros positivos em relação a todos os positivos previstos, conforme representado pela Equação 6:

$$Precisão = \frac{VP}{VP + FP} \quad (6)$$

A revocação é a proporção de verdadeiros positivos em relação a todos os verdadeiros positivos e falsos negativos, representada pela Equação 7:

$$Revocação = \frac{VP}{VP + FN} \quad (7)$$

3.2.5.5 Pontuação F1

O F1 é uma métrica que combina precisão e revocação, atribuindo igual peso a ambas. Sua pontuação varia de 0 a 1, sendo valores mais próximos de 1 indicativos de uma segmentação mais próxima da esperada. A Equação 8 define o cálculo do F1.

$$F1 = \frac{2 \cdot (Precisão \cdot Revocação)}{Precisão + Revocação} \quad (8)$$

O objetivo da avaliação do modelo em cada um dos testes realizados foi analisar o seu desempenho na segmentação de áreas de superfície de água em imagens de satélite. Os dados de teste, com dimensões de 128 x 128 pixels e inclusão da classe em estudo, foram empregados para avaliar o modelo. Cada imagem gerada a partir da aplicação do modelo consistia em probabilidades. Um limite de 50% foi inicialmente estabelecido para distinguir quais pixels pertenciam à classe de interesse (água), representados pelo valor 1, e quais não faziam parte da classe (não água), representados pelo valor 0. No entanto, como parte da análise, outros valores de limite foram testados para avaliar o impacto na segmentação e no desempenho do modelo. Essa variação nos limites permitiu uma análise mais abrangente do modelo em termos das métricas de avaliação.

3.3 Criação da Série Temporal do Volume dos Reservatórios

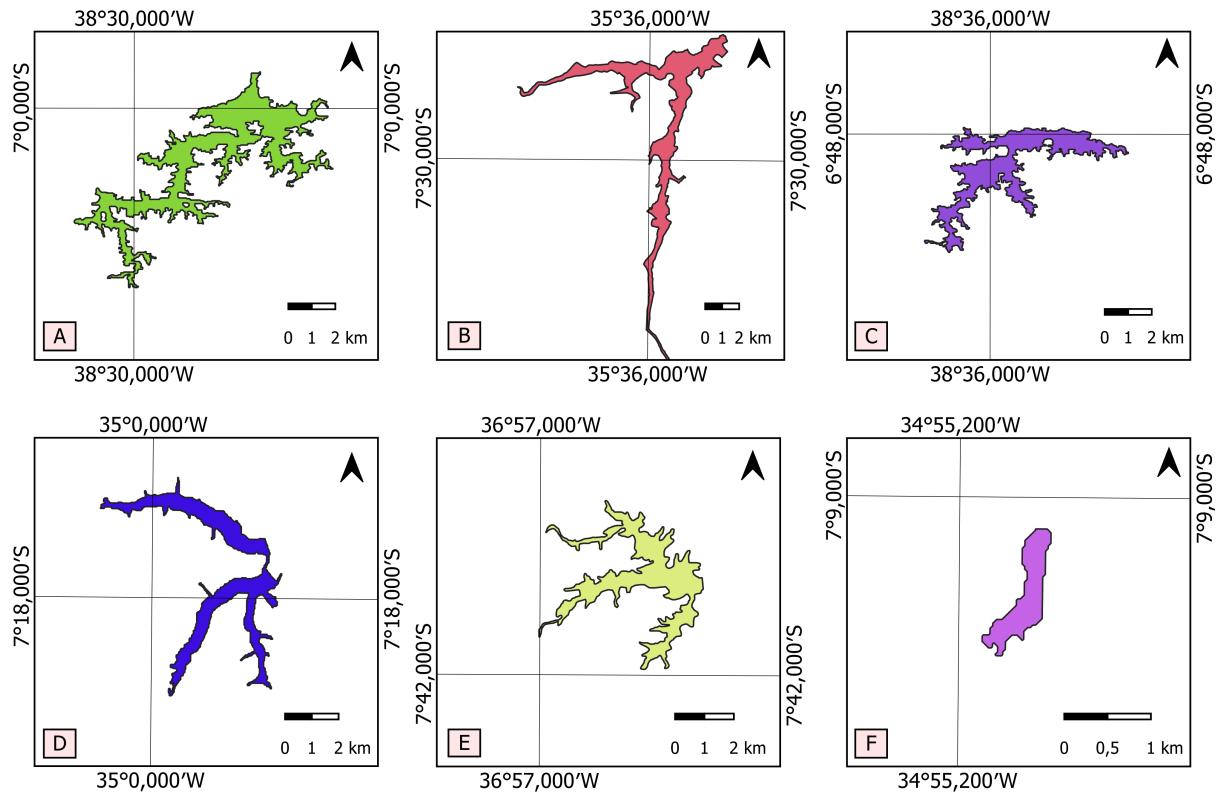
Após a etapa anterior de criação do modelo para segmentação de água em imagens de satélite, esta seção descreverá as etapas envolvidas na formação da série temporal do volume hídrico dos reservatórios selecionados. Inicialmente, foram utilizadas as imagens segmentadas na primeira etapa para estimar a área superficial dos reservatórios hídricos. Com base na área superficial obtida, determinou-se o volume correspondente. Para aprimorar a estimativa da série temporal, foram aplicados procedimentos de pós-processamento nos dados do volume estimado. Por fim, foram empregadas métricas para comparar os resultados do volume obtido estimado pela imagem de satélite com o volume do reservatório disponibilizado pela AESA (2023).

3.3.1 Cálculo do Espelho d’Água

Para determinar a área do espelho d’água dos reservatórios escolhidos, inicialmente, aplicou-se a rede neural desenvolvida nas etapas anteriores para segmentar e classificar os pixels como “água” e “não água” em imagens de satélite. Com essa segmentação, tornou-se possível quantificar o número de pixels que representavam a região ocupada por um determinado corpo d’água. Juntamente com a resolução espacial da imagem, que no conjunto de dados é de $10\text{ m} \times 10\text{ m}$, calculou-se a área da superfície hídrica do reservatório.

Devido ao formato retangular das imagens utilizadas na predição da rede e à necessidade de considerar apenas o corpo d’água do reservatório em estudo, foram utilizadas máscaras para garantir que o pixel contabilizado pertencesse ao reservatório. As máscaras foram obtidas por meio do *shapefile* dos reservatórios disponibilizados pela AESA. A Figura 24 mostra as máscaras utilizadas para cada um dos reservatórios.

Figura 24: Máscara dos reservatórios. a) Engenheiro Ávidos. b) Argemiro de Figueiredo. c) Lagoa do Arroz. d) Gramame/Mamuaba. e) Sumé. f) Marés.



Fonte: Elaborado pela autora.

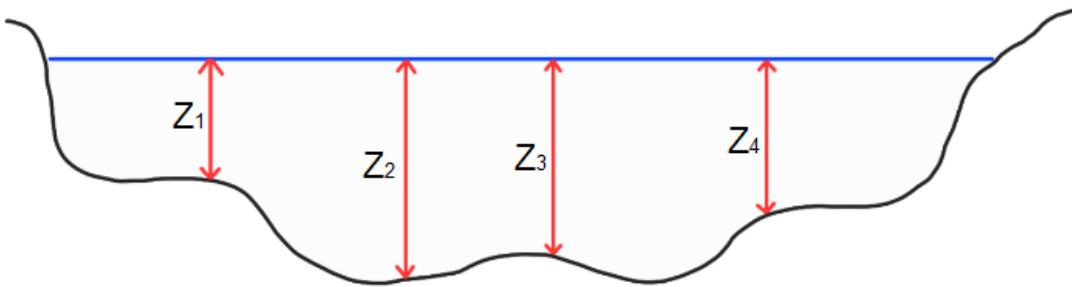
3.3.2 Estimativa do Volume Armazenado

O volume armazenado pode ser estimado através da área do espelho d’água, em conjunto com a Curva Cota x Área x Volume (CAV) específica de cada reservatório. Essas curvas desempenham um papel crucial no monitoramento e na gestão de reservatórios, fornecendo informações sobre o volume e a área do reservatório em relação ao nível da água. Neste estudo, as Curvas CAV específicas dos reservatórios foram disponibilizadas pela Agência Executiva de Gestão das Águas do Estado da Paraíba (AESÁ).

Uma Curva Cota x Área x Volume de um reservatório é uma representação gráfica que relaciona a elevação do terreno (cota) com a área ocupada e o volume de água em uma determinada região. Como os reservatórios em sua maioria apresentam formatos irregulares, com profundidades variáveis em diferentes partes do reservatório, como observado na Figura 25, essa curva ajuda a entender como a área inundada e o volume de água armazenado variam conforme a elevação da água.

Embora representada graficamente, essa curva geralmente é construída a partir de dados coletados e organizados em tabelas. Essas tabelas contêm informações sobre as elevações, áreas e volumes correspondentes, que são então plotadas em um gráfico para visualização e análise. Essa abordagem tabular ajuda a organizar os dados de forma

Figura 25: Representação gráfica de um corte de um reservatório.



Fonte: Elaborado pela autora.

precisa e facilita a criação das curvas para entender as relações entre cota, área e volume em uma determinada região.

Essas curvas CAV serviram como apoio para estimar o volume dos reservatórios com base na área ocupada pela água, obtida por meio da segmentação das imagens de satélite. O volume foi estimado interpolando a área superficial obtida com as imagens de satélite e os dados da curva CAV do reservatório. A curva CAV utilizada para cada reservatório encontra-se no Anexo A.

3.3.3 Pós-processamento da Série Temporal Obtida

Após avaliar os gráficos de monitoramento de volume de água, foram observadas quedas acentuadas nas curvas de alguns reservatórios, uma ocorrência que normalmente não está presente nos gráficos de monitoramento de volume. A presença de nuvens em algumas imagens foi responsável por essa discrepância. Apesar de excluir imagens com mais de 20% de cobertura de nuvens, o método de filtragem aplicado não conseguiu evitar completamente que as nuvens afetassem as curvas. Para representar de forma mais precisa o comportamento real da curva de monitoramento, foi estabelecido um valor máximo de queda de volume para cada um dos corpos d'água analisados. Esse valor foi calculado considerando a queda média no volume de água de cada reservatório, com base em dados de monitoramento fornecidos pela AESA. Quaisquer valores registrados que excedessem esses limites, considerando o período entre as medições, foram ajustados. Esse processo aprimorou a precisão da representação dos dados e compensou o impacto potencial da cobertura de nuvens nas imagens de satélite originais.

3.3.4 Métricas Utilizadas na Avaliação dos Resultados

Além da análise visual, para comparar as duas séries temporais, uma obtida por meio da metodologia descrita neste trabalho para o volume de reservatórios hídricos e

a outra disponibilizada pelo órgão de monitoramento hídrico do estado (AESÁ), considerada a verdade terreste, foram utilizados algumas métricas. As métricas de avaliação incluíram o Erro Médio Quadrático, Erro Percentual Médio Absoluto, Coeficiente de Determinação (R^2) e Coeficiente de Correlação de *Pearson* (r).

3.3.4.1 Erro Médio Quadrático (RMSE - *Root Mean Square Error*)

O RMSE é uma métrica que quantifica a diferença entre os valores reais (y_i) e os valores previstos (\hat{y}_i). Quanto menor o RMSE, melhor, indicando que as duas curvas são próximas uma da outra. A fórmula do RMSE é dada pela Equação 9:

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (9)$$

3.3.4.2 Erro Percentual Médio Absoluto (MAPE - *Mean Absolute Percentage Error*)

O MAPE é uma métrica de avaliação de precisão amplamente utilizada em previsões e estimativas. Ele expressa o erro médio como uma porcentagem do valor real. A fórmula do MAPE é dada pela Equação 10:

$$MAPE = \frac{1}{n} \sum_{i=1}^n \left(\frac{|y_i - \hat{y}_i|}{y_i} \right) \times 100 \quad (10)$$

onde n é o número de observações ou pontos de dados na série temporal, y_i é o valor real na série temporal e \hat{y}_i é o valor previsto ou estimado na série temporal.

O cálculo do MAPE envolve a diferença absoluta entre os valores reais e previstos, normalizada pelo valor real, resultando em uma média ponderada por porcentagem. Um valor menor de MAPE indica uma maior precisão nas previsões.

3.3.4.3 Coeficiente de Determinação (R^2)

O coeficiente de determinação, frequentemente denotado como R^2 , mede a proporção da variabilidade na série temporal da imagem de satélite que é explicada pela série “verdade terreste”. Valores mais próximos de 1 indicam uma boa correspondência

entre as curvas. A fórmula do R^2 é mostrada pela Equação 11:

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2} \quad (11)$$

onde \bar{y} representa a média dos valores reais.

3.3.4.4 Coeficiente de Correlação de *Pearson*

O coeficiente de correlação de *Pearson*, denotado por r , é uma métrica comum para análise de correlação entre duas séries temporais. Ele mede a correlação linear entre as duas séries, variando de -1 (correlação negativa perfeita) a 1 (correlação positiva perfeita), com 0 indicando ausência de correlação. Quanto mais próximo de 1 (ou -1), maior a correlação entre as séries. A fórmula do coeficiente de correlação de *Pearson* é mostrada na Equação 12:

$$r = \frac{\sum_{i=1}^n (y_i - \bar{y})(\hat{y}_i - \bar{\hat{y}})}{\sqrt{\sum_{i=1}^n (y_i - \bar{y})^2 \sum_{i=1}^n (\hat{y}_i - \bar{\hat{y}})^2}} \quad (12)$$

onde \bar{y} e $\bar{\hat{y}}$ representam as médias das séries de valores reais e previstos, respectivamente.

4 RESULTADOS E DISCUSSÕES

Este capítulo apresenta e analisa os resultados obtidos por meio do modelo de segmentação criado, considerando as diversas abordagens discutidas no capítulo anterior. Além disso, examina em detalhes os resultados das séries temporais de volume hídrico dos reservatórios selecionados.

4.1 Segmentação de Imagens de Satélites

Nesta seção, serão apresentados os resultados obtidos por meio da rede desenvolvida com base na arquitetura U-Net. Foram testadas quatro abordagens diferentes para a criação do modelo de segmentação, conforme apresentado na Figura 23. Todos os testes foram conduzidos usando a técnica de validação cruzada com 5 *folds*. Ao final, foram calculadas as médias e os desvios padrão de cada métrica de desempenho.

No primeiro teste, foi empregada a primeira abordagem, na qual o modelo U-Net foi treinado sem a aplicação da etapa de aumento de dados. Os resultados do Teste 1 indicam um desempenho significativo do modelo de aprendizado de máquina na tarefa de segmentação. A acurácia do modelo foi de 98,90%, com uma variação de $\pm 0,001$. A precisão foi de 97,30%, com uma variação de $\pm 0,003$. A revocação atingiu 98,10%, com uma variação de $\pm 0,002$, e o valor F1 foi de 97,70%, com uma variação de $\pm 0,002$. O coeficiente *Dice* ficou em 96,42%, com uma variação de $\pm 0,005$, e o Índice de Jaccard (IoU) em 95,50%, com uma variação de $\pm 0,004$.

O Teste 2, que utilizou a técnica de aumento de dados. A acurácia do modelo foi de 99,05%, com uma variação de $\pm 0,0$, a precisão de 97,55%, com uma variação de $\pm 0,002$, a revocação de 98,17%, com uma variação de $\pm 0,001$, o valor F1 de 97,86%, com uma variação de $\pm 0,001$, o coeficiente *Dice* de 96,86%, com uma variação de $\pm 0,001$, e o Índice de Jaccard (IoU) de 95,81%, com uma variação de $\pm 0,001$. Os resultados do Teste 2 apontam para um desempenho superior quando comparado ao Teste 1.

O Teste 3 combinou o modelo U-Net utilizando a técnica de aprendizado por transferência utilizando a VGG16, mas sem aplicar o aumento de dados. Os resultados do Teste 3 indicam que o uso de técnicas de aprendizado não proporcionou resultados melhores do que o Teste 2, com exceção da métrica *Dice*. A acurácia do modelo foi de 98,95%, com uma variação de $\pm 0,001$. A precisão de 97,53%, com uma variação de $\pm 0,002$, a revocação de 98,07%, com uma variação de $\pm 0,001$, o valor F1 de 97,80%, com uma variação de $\pm 0,001$, o coeficiente *Dice* de 96,87%, com uma variação de $\pm 0,001$, e o Índice de Jaccard (IoU) de 95,69%, com uma variação de $\pm 0,001$.

No Teste 4, foram combinadas as técnicas do Teste 2 e 3, incluindo o aumento de dados no conjunto de treinamento e o uso de aprendizado por transferência. A acurácia

do modelo foi de 98,86%, com uma variação de $\pm 0,002$, a precisão de 97,47%, com uma variação de $\pm 0,009$, a revocação de 97,41%, com uma variação de $\pm 0,007$, o valor F1 de 97,44%, com uma variação de $\pm 0,004$, o coeficiente *Dice* de 96,21%, com uma variação de $\pm 0,008$, e o Índice de Jaccard (IoU) de 95,00%, com uma variação de $\pm 0,008$.

As Tabelas 11 e 12 fornecem uma visão detalhada dos resultados dos quatro testes realizados. Ao analisar esses resultados, é possível observar que o Teste 2 apresentou o melhor desempenho em termos de *IoU*, acurácia, precisão, revocação e pontuação *F1*. A única métrica na qual o Teste 3 superou os demais foi na métrica *Dice*. Embora haja semelhanças nos resultados, o modelo do Teste 2 se destacou como o mais eficaz. Portanto, o modelo do Teste 2 foi selecionado para realizar a segmentação da água nas imagens de satélite dos reservatórios escolhidos.

Tabela 11: Resultados dos testes realizados em segmentação de água nas medidas de IoU e Dice.

	IoU	Dice
Teste 1	95,50% $\pm 0,004$	96,41% $\pm 0,005$
Teste 2	95,81%$\pm 0,001$	96,86% $\pm 0,001$
Teste 3	95,69% $\pm 0,001$	96,87%$\pm 0,001$
Teste 4	95,00% $\pm 0,008$	96,21% $\pm 0,008$

Fonte: Elaborado pela autora.

Tabela 12: Resultados dos testes realizados em segmentação de água nas demais medidas.

	Acurácia	Precisão	Revocação	F1
Teste 1	98,90% $\pm 0,001$	97,30% $\pm 0,003$	98,10% $\pm 0,002$	97,70% $\pm 0,002$
Teste 2	99,05%$\pm 0,0$	97,55%$\pm 0,002$	98,17%$\pm 0,001$	97,86%$\pm 0,001$
Teste 3	98,95% $\pm 0,0$	97,53% $\pm 0,002$	98,07% $\pm 0,001$	97,80% $\pm 0,001$
Teste 4	98,86% $\pm 0,002$	97,47% $\pm 0,009$	97,41% $\pm 0,007$	97,44% $\pm 0,004$

Fonte: Elaborado pela autora.

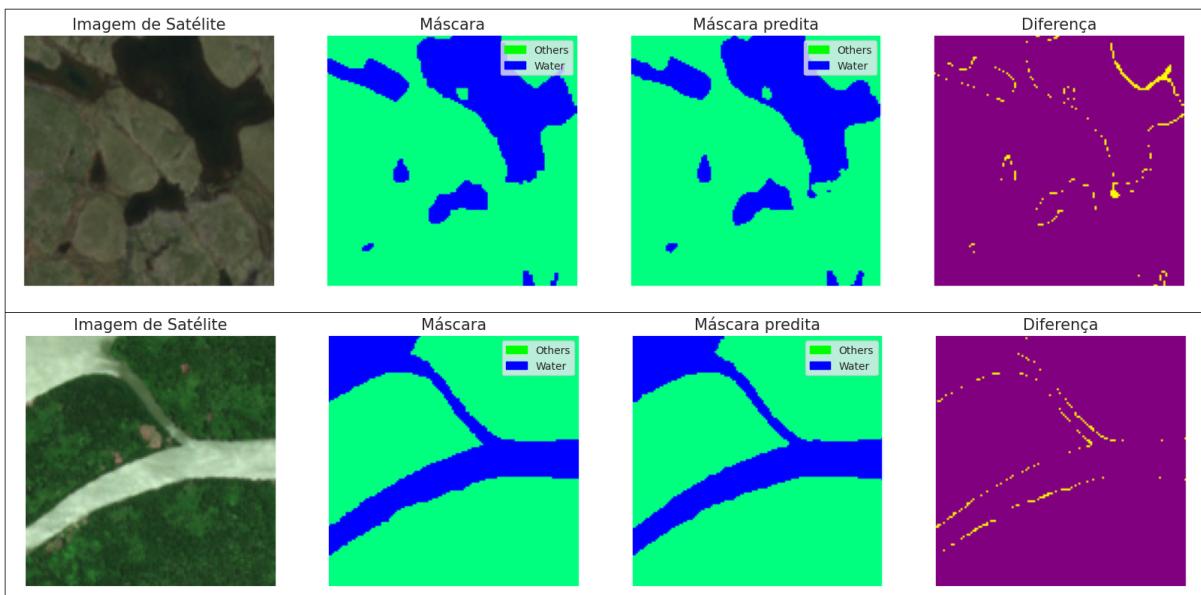
A Figura 26 exibe dois exemplos das previsões geradas pelo modelo do Teste 2 no conjunto de teste. Cada exemplo compreende a imagem de satélite com as bandas RGB, a máscara de referência (também conhecida como ”verdade terrestre”), a máscara obtida e a diferença entre a máscara de referência e a máscara obtida. A máscara de referência é uma representação das áreas de água presentes nas imagens de satélite, e foi criada manualmente pelo autor do banco de dados utilizado neste estudo.

É perceptível que as máscaras obtidas se aproximam da máscara de referência, evidenciando a eficiência da técnica em identificar e separar os pixels correspondentes à água em imagens de satélite. As maiores discrepâncias são identificadas nas bordas dos corpos d’água, onde o modelo enfrenta dificuldades em distinguir entre os pixels de água e não água. Ressalta-se que cada exemplo apresenta características distintas, tanto na

imagem original, quanto nas máscaras de referência e obtidas pela rede. Isso evidencia a versatilidade da rede em lidar com imagens de diferentes complexidades e conteúdos.

Embora as máscaras de referência tenham sido criadas pelo autor original do banco de dados, o mérito deste estudo reside na implementação e avaliação das Redes Neurais Convolucionais para a segmentação de áreas de água em imagens de satélite. Além da aplicação e análise das técnicas propostas neste trabalho para aprimorar a segmentação automática de corpos d'água.

Figura 26: Exemplos das previsões geradas pelo modelo do Teste 2 no conjunto de teste



Fonte: Elaborado pela autora.

4.2 Série Temporal do Volume dos Reservatórios

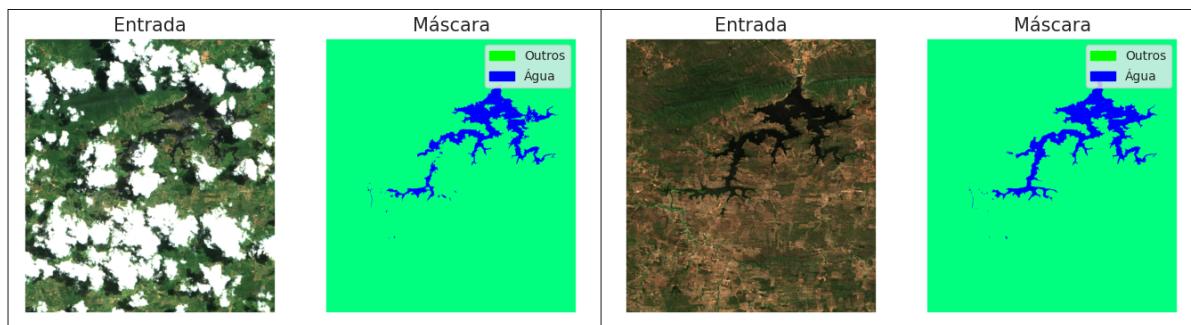
Com base no modelo obtido no Teste 2, as imagens de satélite dos reservatórios selecionados foram processadas para extrair a área de água. Utilizando a rede neural convolucional desenvolvida para este estudo, a área da superfície da água dos reservatórios escolhidos foi determinada com sucesso usando imagens de satélite. Inicialmente, a área da superfície da água de cada reservatório dentro de uma imagem foi estabelecida identificando os pixels classificados como água. Em seguida, multiplicou-se a contagem de pixels identificados pela área de resolução espacial deles, que é de 10 metros. O gráfico de monitoramento de volume foi derivado dos dados de área da superfície da água dos reservatórios, juntamente com as curvas CAV.

Essa estimativa do volume de água nas imagens permitiu a criação de gráficos de monitoramento do volume hídrico ao longo do tempo para cada reservatório. Para avaliar

a série temporal resultante, foram empregadas métricas como *RMSE*, *MAPE*, o coeficiente de determinação R^2 e o coeficiente de correlação de *Pearson*.

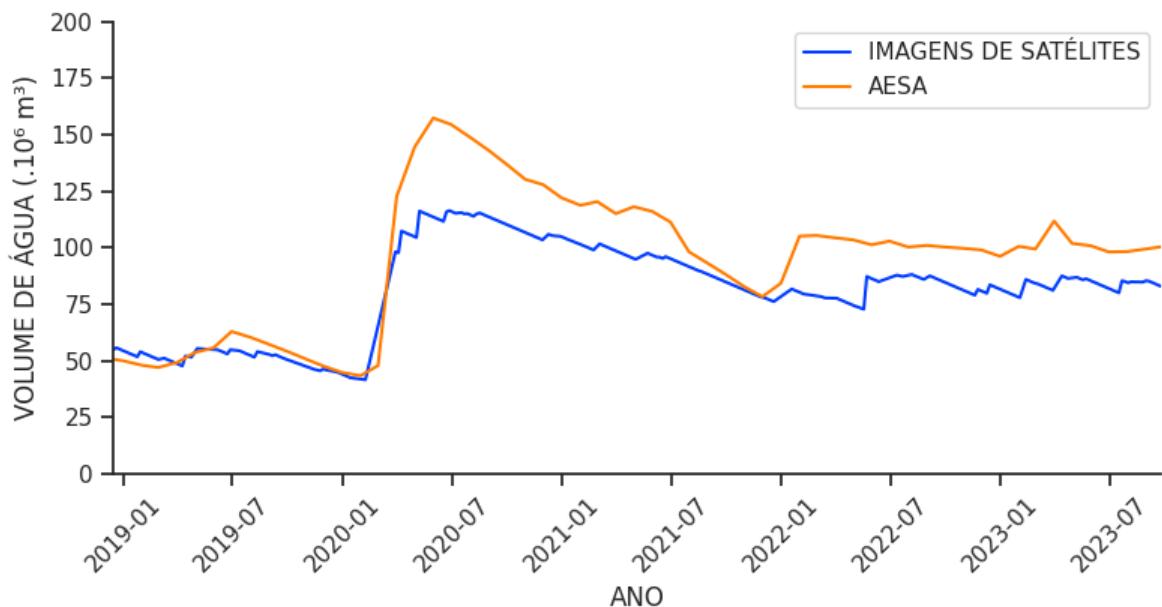
O primeiro reservatório avaliado foi o Engenheiro Ávidos. A Figura 27 apresenta dois exemplos da imagem original do reservatório e a máscara correspondente gerada pela rede treinada. Além disso, a Figura 28 exibe o gráfico de série temporal obtido para o reservatório Engenheiro Ávidos, comparando-o com os dados fornecidos pela agência que monitora os reservatórios de água no estado da Paraíba, a AESA.

Figura 27: Exemplos da imagem do reservatório Engenheiro Ávidos com suas respectivas máscaras obtidas pela rede.



Fonte: Elaborado pela autora.

Figura 28: A série temporal obtida para o reservatório Engenheiro Ávidos, comparando-o com os dados disponibilizados pela AESA.



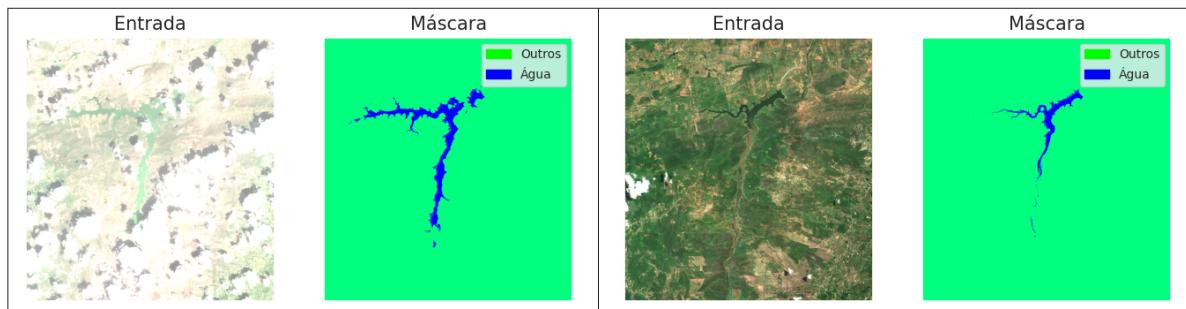
Fonte: Elaborado pela autora.

Os resultados obtidos para o reservatório Engenheiro Ávidos foram: *RMSE* de 18,79 hm^3 , *MAPE* de 14,53%, o coeficiente de determinação R^2 atingiu 0,62, e o coeficiente de *Pearson* aplicado às duas curvas geradas resultou em 0,96. Esses valores sugerem uma

relação sólida entre as medições por imagens de satélite e a verdade terrestre, embora com alguma variação.

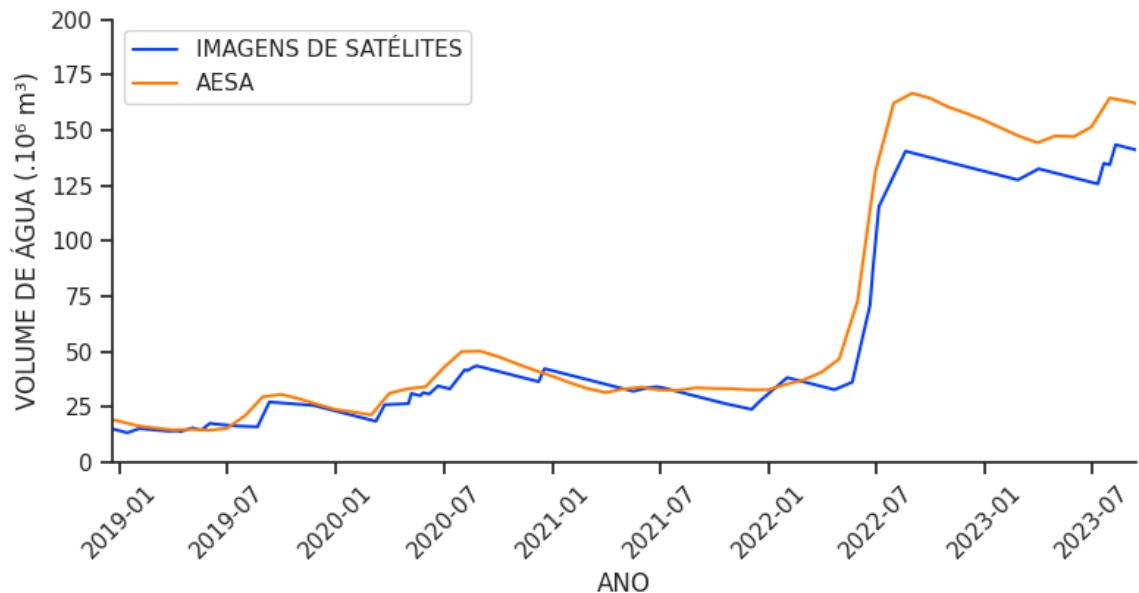
O Argemiro de Figueiredo, segundo reservatório avaliado, apresentou resultados melhores. A Figura 29 apresenta dois exemplos da imagem original e da máscara gerada pela rede treinada no Teste 2. Além disso, a Figura 30 mostra o gráfico da série temporal obtido para o reservatório Argemiro de Figueiredo, comparado com os dados disponibilizados pela AESA.

Figura 29: Exemplos da imagem do reservatório Argemiro de Figueiredo com suas respectivas máscaras obtidas pela rede.



Fonte: Elaborado pela autora.

Figura 30: A série temporal obtida para o reservatório Argemiro de Figueiredo, comparando-o com os dados disponibilizados pela AESA.



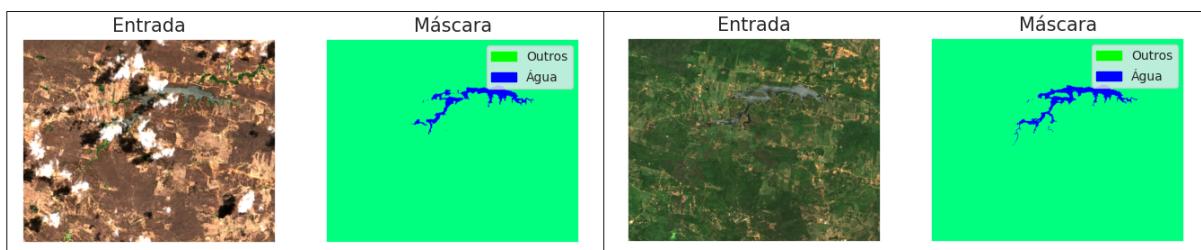
Fonte: Elaborado pela autora.

Para o reservatório Argemiro de Figueiredo, o *RMSE* foi de 13,62 hm^3 , o *MAPE* foi de 13,31%, o coeficiente de determinação R^2 foi de 0,94, e o coeficiente de *Pearson* foi de 0,99. Observa-se que o resultado para o reservatório Argemiro de Figueiredo foi

superior em relação ao reservatório anterior. Suas métricas indicam um *MAPE* um pouco menor que o reservatório anterior, com um R^2 bastante alto e um coeficiente de *Pearson* muito próximo de 1, o que sugere uma relação muito forte entre as séries temporais.

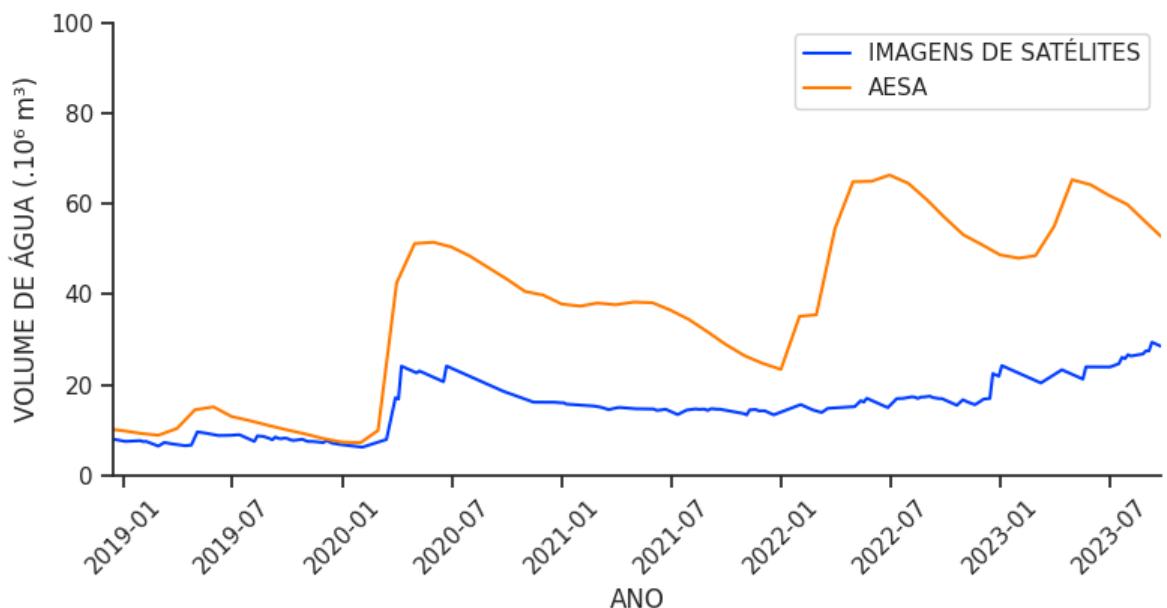
O próximo reservatório é o Lagoa do Arroz. A Figura 31 apresenta dois exemplos da imagem original e da máscara gerada pela rede U-Net treinada com a técnica de aumento de dados, no reservatório Lagoa do Arroz. Além disso, a Figura 32 exibe o gráfico da série temporal obtido para o reservatório, comparando-o com os dados da AESA.

Figura 31: Exemplos da imagem do reservatório Lagoa do Arroz com suas respectivas máscaras obtidas pela rede.



Fonte: Elaborado pela autora.

Figura 32: A série temporal obtida para o reservatório Lagoa do Arroz, comparando-o com os dados disponibilizados pela AESA.



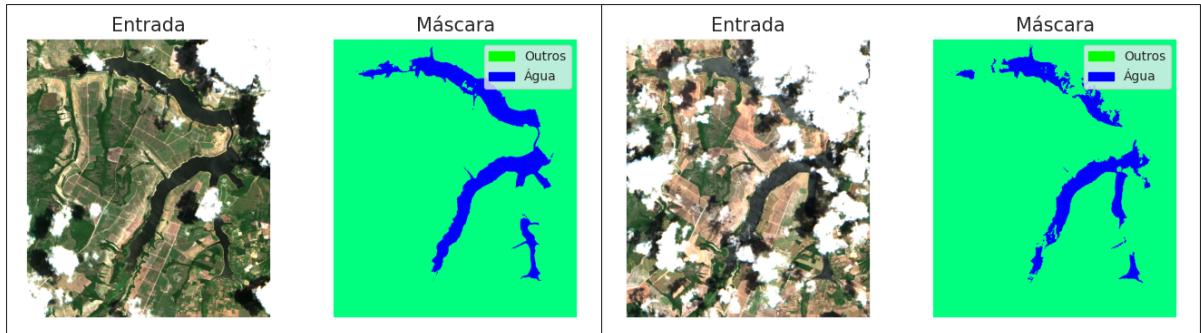
Fonte: Elaborado pela autora.

Nesse reservatório, foi observado um desempenho inferior, com um *RMSE* de 26,22 hm^3 , um *MAPE* de 50,43%, um R^2 negativo de -0,87 e um coeficiente de *Pearson* de 0,85.

O próximo reservatório analisado foi o Gramame/Mamuaba. A Figura 33 apresenta dois exemplos da imagem original e da máscara gerada pela rede U-Net treinada com a

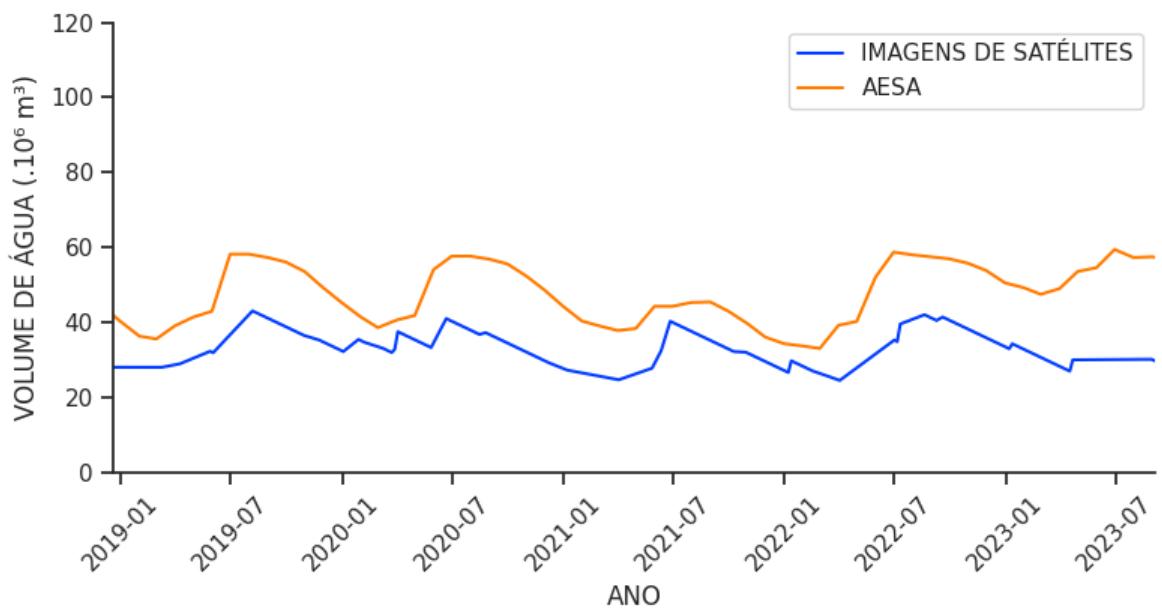
técnica de aumento de dados. Além disso, a Figura 34 mostra o gráfico da série temporal obtido para o reservatório Gramame/Mamuaba, comparando-o com os dados da AESA.

Figura 33: Exemplos da imagem do reservatório Gramame/Mamuaba com suas respectivas máscaras obtidas pela rede.



Fonte: Elaborado pela autora.

Figura 34: A série temporal obtida para o reservatório Gramame/Mamuaba, comparando-o com os dados disponibilizados pela AESA.



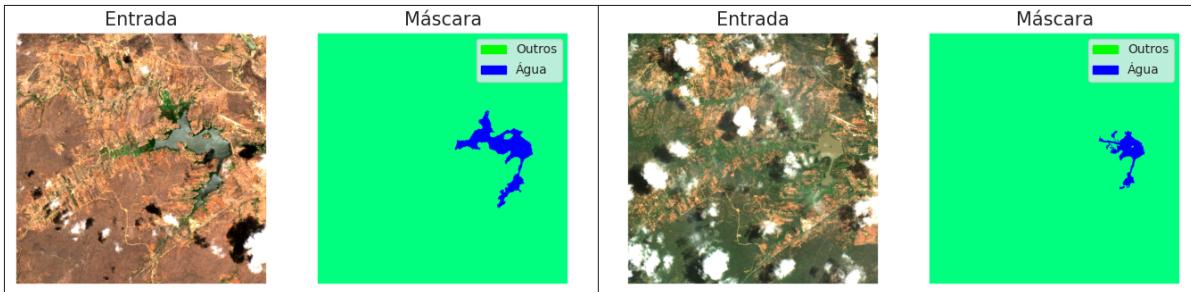
Fonte: Elaborado pela autora.

O reservatório Gramame/Mamuaba apresentou os seguintes resultados: um *RMSE* de 16,35 hm^3 , um *MAPE* de 30,61%, um R^2 negativo de -3,04 e um coeficiente de *Pearson* de 0,62.

Para o reservatório Sumé, a Figura 35 apresenta dois exemplos da imagem original e da máscara gerada pela rede U-Net treinada com a técnica de aumento de dados. Além disso, a Figura 36 exibe o gráfico da série temporal obtido para o reservatório Sumé, comparando-o com os dados da AESA. Os resultados das métricas para este reservatório

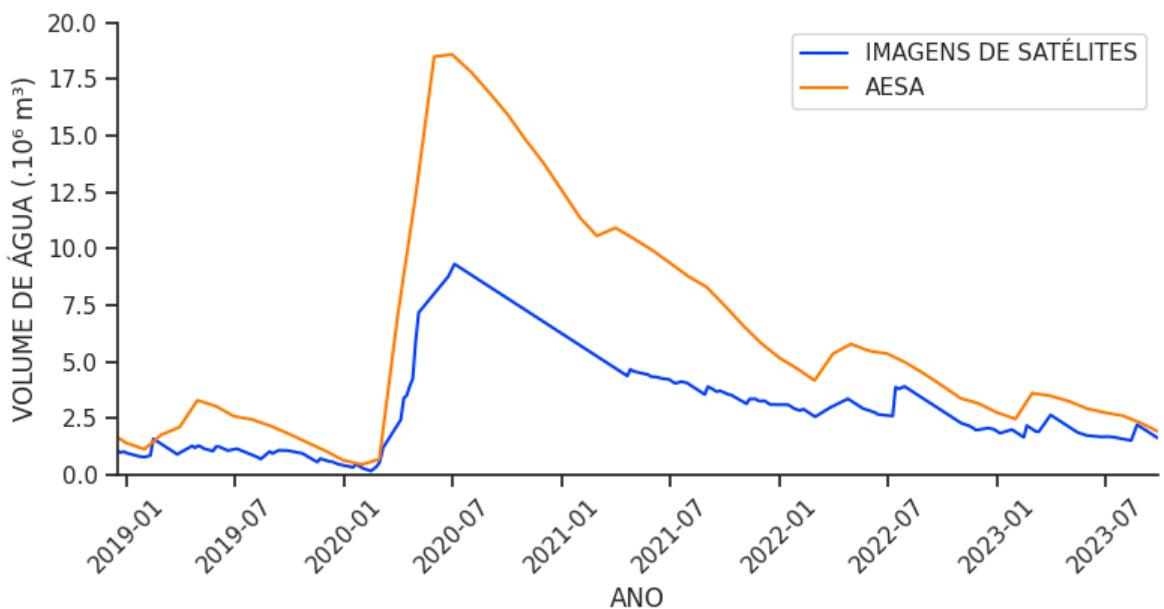
foram: um *RMSE* de $4,08 \text{ hm}^3$, um *MAPE* de 43,28%, um R^2 de 0,33 e um coeficiente de *Pearson* de 0,98.

Figura 35: Exemplos da imagem do reservatório Sumé com suas respectivas máscaras obtidas pela rede.



Fonte: Elaborado pela autora.

Figura 36: A série temporal obtida para o reservatório Sumé, comparando-o com os dados disponibilizados pela AESA.

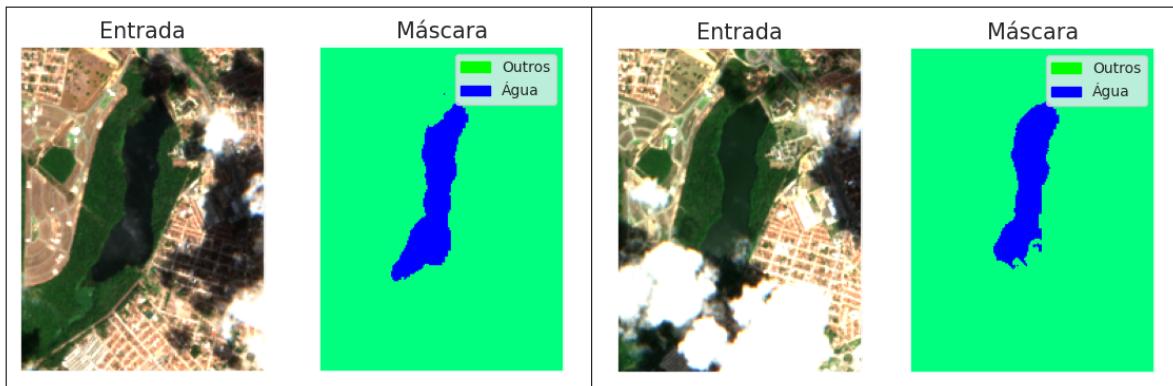


Fonte: Elaborado pela autora.

E, por fim, o reservatório é o Marés. A Figura 37 apresenta dois exemplos da imagem original e da máscara gerada pela rede treinada no Teste 2. Além disso, a Figura 38 mostra o gráfico da série temporal obtido para o reservatório Marés, comparado com os dados disponibilizados pela Agência que Monitora os Reservatórios Hídricos do Estado (AESÁ).

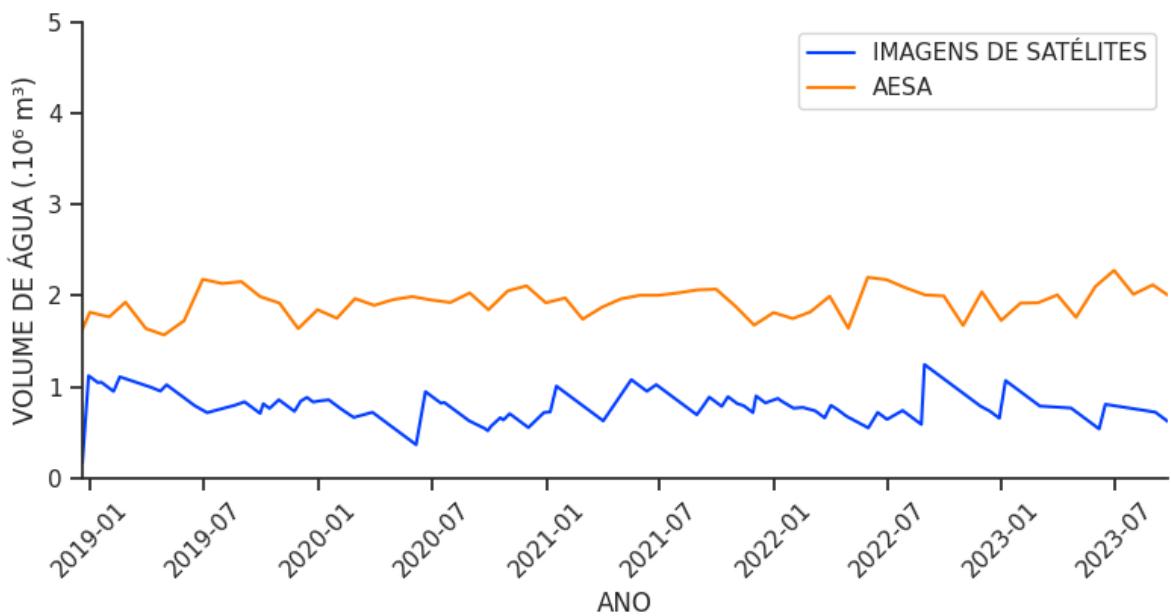
Para o reservatório de Marés, o menor reservatório entre os selecionados, foram observadas características singulares em sua série temporal. O *RMSE* de $1,16 \text{ hm}^3$ e o *MAPE* de 58,38% revelam as discrepâncias entre os volumes previstos pelo modelo e os

Figura 37: Exemplos da imagem do reservatório Marés com suas respectivas máscaras obtidas pela rede.



Fonte: Elaborado pela autora.

Figura 38: A série temporal obtida para o reservatório Marés, comparando-o com os dados disponibilizados pela AESA.



Fonte: Elaborado pela autora.

dados considerados como verdade terrestre. Além disso, o coeficiente de determinação R^2 e o coeficiente de *Pearson*, registrando -52,30 e -0,26, respectivamente, indicam uma correlação fraca e negativa entre as previsões do modelo e os dados observados. O valor próximo a zero do coeficiente de *Pearson* sugere uma relação mínima entre as variáveis, enquanto o R^2 negativo indica que o modelo não se ajusta bem aos dados e não é capaz de explicar a variação observada.

Ao interpretar esses resultados, é crucial considerar a natureza específica da evolução temporal do reservatório de Marés. Este apresenta uma variação mínima em seu volume, com oscilações de amplitude reduzida e uma aparência de ruído ao longo do tempo. Essa

constância na capacidade do reservatório impacta diretamente nas métricas utilizadas, especialmente no coeficiente de *Pearson*.

O coeficiente de *Pearson* é conhecido por ser sensível à variância dos dados. Em situações em que a variância é baixa, como é o caso deste reservatório, a capacidade do coeficiente de *Pearson* de refletir a verdadeira relação entre as variáveis é limitada. Isso ocorre porque, em situações de baixa variância, a divisão por zero no cálculo do coeficiente de *Pearson* pode comprometer a interpretação do mesmo, tornando-o menos robusto.

É relevante destacar que a aparente aleatoriedade na curva observada no gráfico da série temporal do reservatório Marés pode ser atribuída à sua evolução temporal quase constante. A variação muito pequena e de modo aparentemente aleatório pode ser um reflexo da limitada variabilidade nos dados, influenciando diretamente nas métricas quantitativas adotadas.

A Tabela 13 resume as análises das métricas para os seis reservatórios avaliados. No geral, os reservatórios Engenheiro Ávidos e Argemiro de Figueiredo, que possuem as maiores capacidades de armazenamento entre os selecionados no estudo, demonstraram um ajuste de modelo superior. Apresentaram *MAPEs* mais baixos, R^2 mais elevados e coeficientes de *Pearson* mais fortes, indicando uma relação mais estreita entre as séries temporais de satélite e os dados reais do reservatório.

Tabela 13: Resultados dos testes realizados em segmentação de água nas demais medidas.

Reservatório	Capacidade Máxima (m^3)	RMSE (hm ³)	MAPE (%)	R^2	Pearson
Engenheiro Ávidos	293.617.376	18,79	14,52	0,62	0,96
Argemiro de Figueiredo	253.142.247	13,62	13,31	0,94	0,99
Lagoa do Arroz	80.388.537	26,22	50,43	-0,87	0,85
Gramame/Mamuaba	56.937.000	16,35	30,61	-3,04	0,62
Sumé	44.864.100	4,08	43,28	0,33	0,98
Marés	2.136.637	1,16	58,38	-52,31	-0,26

Fonte: Elaborado pela autora.

Por outro lado, os demais reservatórios tiveram um desempenho inferior, com pelo menos uma das métricas sugerindo um ajuste menos eficaz do modelo. No caso de Lagoa do Arroz, embora tenha obtido um coeficiente de *Pearson* significativo de 0,85, sugerindo uma boa relação linear, o *MAPE* foi de 50%, indicando uma alta discrepância entre os valores estimados e os dados da AESA. Uma situação semelhante ocorreu com o reservatório

de Sumé, onde o coeficiente de *Pearson* foi de 0,98, mas o *MAPE* foi relativamente alto, atingindo 43,28%. Além desses, os reservatórios Gramame/Mamuaba e Marés apresentaram valores de R^2 negativos, sinalizando que o modelo não se ajusta adequadamente aos dados, falhando em explicar a variação observada.

Reservatórios com maior capacidade máxima parecem apresentar resultados melhores. No entanto, é importante observar que outros fatores também podem influenciar os resultados, e a capacidade máxima não é o único indicador a considerar ao avaliar o desempenho do modelo.

Uma hipótese pertinente a ser considerada é que a presença de nuvens pode obstruir a visibilidade do reservatório nas imagens de satélite, dificultando a obtenção de estimativas precisas dos níveis de água. Além disso, a resolução espacial das imagens desempenha um papel significativo. Reservatórios maiores têm uma vantagem, como no caso do reservatório Engenheiro Ávidos e do Argemiro de Figueiredo, já que a resolução espacial de 10 metros (a resolução das imagens de satélite utilizadas neste estudo) pode permitir uma melhor visualização e estimativa dos níveis de água em reservatórios maiores. No entanto, essa resolução espacial pode não ser suficiente ao analisar reservatórios menores, nos quais os detalhes se tornam mais críticos.

Outro fator que pode contribuir para as diferenças nos resultados é a localização geográfica dos reservatórios, especialmente aqueles situados no litoral, sujeitos a condições climáticas instáveis e à presença de nuvens. Portanto, é crucial considerar a sazonalidade das condições climáticas ao analisar reservatórios nessas regiões.

Esses resultados oferecem informações valiosas sobre a eficácia do uso de imagens de satélite na estimativa dos reservatórios hídricos no estado da Paraíba. Além disso, ressaltam a importância de considerar diferentes variáveis e fatores ao analisar os reservatórios, especialmente aqueles que apresentaram resultados menos satisfatórios.

5 CONSIDERAÇÕES FINAIS

O monitoramento de reservatórios hídricos é tradicionalmente realizado *in loco*, por meio de uma rede de estações de medição fluviométricas, pluviométricas, de qualidade da água e outras. No entanto, para um país de tamanho continental como o Brasil, essa rede não é capaz de fornecer uma cobertura abrangente. Para enfrentar esse desafio, este estudo propõe a complementação do monitoramento usando técnicas de aprendizado profundo e imagens de satélite de sensoriamento remoto.

Os resultados destacaram variações significativas no desempenho do modelo de segmentação de água em diferentes reservatórios. Enquanto alguns, como Argemiro de Figueiredo e Engenheiro Ávidos, revelaram resultados promissores, outros, como Marés e Gramame/Mamuaba, apresentaram desafios consideráveis. Essas análises permitiram a avaliação da eficácia do modelo e da metodologia utilizada para o monitoramento dos reservatórios, identificando peculiaridades e fatores que podem afetar a precisão das estimativas. Dentre esses fatores, incluem-se a presença de nuvens, a resolução espacial das imagens de satélite e a localização geográfica dos reservatórios.

Outro aspecto a ser ponderado é que este estudo apresenta algumas limitações. Por exemplo, além da possível interferência da cobertura de nuvens na precisão das imagens de satélite, a eficácia do método está condicionada à disponibilidade e precisão das curvas CAV.

Esses resultados fornecem uma base para pesquisas futuras e melhorias na aplicação de imagens de satélite para o monitoramento de reservatórios hídricos. Também destacam a importância de considerar variáveis complexas ao aplicar essa técnica em diferentes contextos geográficos e climáticos.

No geral, este estudo contribui para a compreensão da aplicação de técnicas de aprendizado profundo e sensoriamento remoto na estimativa dos níveis de água em reservatórios hídricos, destacando seu potencial como uma ferramenta valiosa e complementar para o monitoramento de recursos hídricos, em um país de dimensões continentais como o Brasil.

Pesquisas futuras podem se concentrar em aprimorar a robustez do modelo para lidar com imagens com maior cobertura de nuvens. Além disso, explorar a integração de outros conjuntos de dados de sensoriamento remoto pode potencialmente melhorar a precisão das estimativas de volume de água. Investigações adicionais também podem considerar a aplicação deste método a outros tipos de corpos d'água, como rios e lagos, a fim de demonstrar sua versatilidade e ampla aplicação.

REFERÊNCIAS

- ABILEAH, R.; VIGNUDELLI, S.; SCOZZARI, A. A completely remote sensing approach to monitoring reservoirs water volume. *IWTC*, v. 15, 01 2011.
- ABIRAMI, S.; CHITRA, P. Chapter fourteen - energy-efficient edge based real-time healthcare support system. In: RAJ, P.; EVANGELINE, P. (Ed.). *The Digital Twin Paradigm for Smarter Systems and Environments: The Industry Use Cases*. Elsevier, 2020, (Advances in Computers, 1). p. 339–368. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S0065245819300506>>.
- ACHARYA, T. et al. Identification of water bodies in a landsat 8 oli image using a j48 decision tree. *Sensors*, v. 16, p. 1075, 07 2016.
- AESA. Agência Executiva de Gestão das Águas do Estado da Paraíba. Monitoramento do volume dos açudes do estado da paraíba. 2023.
- AFRIDI, M. J.; ROSS, A.; SHAPIRO, E. M. On automated source selection for transfer learning in convolutional neural networks. *Pattern Recognition*, v. 73, p. 65–75, 2018. ISSN 0031-3203. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S0031320317302881>>.
- AGUILAR, R. et al. A cloud-based multi-temporal ensemble classifier to map smallholder farming systems. *Remote sensing*, MDPI, v. 10, n. 5, p. 729, 2018.
- ANA. Agência Nacional de Águas e Saneamento Básico. Plano de recursos hídricos da bacia hidrográfica do rio piancó-piranhas-açu: Resumo executivo. Brasília-DF, 2016.
- _____. Agência Nacional de Águas e Saneamento Básico. Reservatórios do semiárido brasileiro: Hidrologia, balanço hídrico e operação. Brasília-DF, p. 88, 2017.
- _____. Agência Nacional de Águas e Saneamento Básico. Plano nacional de segurança hídrica. Brasília-DF, 2019.
- _____. Agência Nacional de Águas e Saneamento Básico. Atlas brasil – abastecimento urbano de Água. Brasília-DF, 2021.
- _____. Agência Nacional de Águas e Saneamento Básico. Atlas Águas: Resumo de investimentos nos estados. Brasília-DF, 2021.
- ARAÚJO, F. H. et al. Redes neurais convolucionais com tensorflow: Teoria e prática. In: _____. [S.I.]: SOCIEDADE BRASILEIRA DE COMPUTAÇÃO. III Escola Regional de Informática do Piauí. Livro Anais-Artigos e Minicursos, 2017. p. 382–406. ISBN 978-85-7669-395-6.
- ARROYO-FIGUEROA, G.; SUCAR, L.; VILLAVICENCIO, A. Fuzzy intelligent system for the operation of fossil power plants. *Engineering Applications of Artificial Intelligence*, v. 13, p. 431–439, 08 2000.
- ASCHBACHER, J.; MILAGRO-PÉREZ, M. P. The european earth monitoring (gmes) programme: Status and perspectives. *Remote Sensing of Environment*, v. 120, p. 3–8, 2012. ISSN 0034-4257. The Sentinel Missions - New Opportunities for Science.

AVISSE, N. et al. Monitoring small reservoirs' storage with satellite remote sensing in inaccessible areas. *Hydrology and Earth System Sciences*, v. 21, p. 6445–6459, 12 2017.

BANDIM, C.; GALVINCIO, J. Mapeamento das áreas de armazenamento de água em depressão, usando dados lidar: Estudo de caso avenida caxangá. *Revista Brasileira de Geografia Física*, v. 14, p. 058, 04 2021.

BARBOSA, A. et al. Seis anos de seca: Análise espaço-temporal dos espelhos d'água dos reservatórios do ceará por sensoriamento remoto. *Revista Brasileira de Geografia Física*, v. 14, p. 2220–2241, 08 2021.

BARROS, A. C.; SILVA, T. J.; COSTA, D. M. Sensoriamento remoto na análise ambiental da microbacia do córrego da água amarela, itaberá-SP. *Holos Environment*, v. 16, n. 1, p. 27–35, ago. 2016.

BELTRÃO, B. A. et al. Projeto Cadastro de fontes de abastecimento por água subterrânea - Estado da Paraíba. Diagnóstico do município de Itatuba. Ministério de Minas e Energia, Recife, p. 20, 2005.

BHADORIA, R. K. et al. Chapter 7 - IoT-based location-aware smart healthcare framework with user mobility support in normal and emergency scenario: a comprehensive survey. In: BALAS, V. E.; PAL, S. (Ed.). *Healthcare Paradigms in the Internet of Things Ecosystem*. Academic Press, 2021. p. 137–161. ISBN 978-0-12-819664-9. Disponível em: <<https://www.sciencedirect.com/science/article/pii/B9780128196649000077>>.

BRAGA, F. L. A. *Usos DA Água e Desperdício no Perímetro Irrigado do Açude de Lagoa do Arroz-PB*. 2016. 76 p. Dissertação (Mestrado) — Universidade Federal de Campina Grande, Cajazeiras-PB, 2016.

BRAHME, A. *Comprehensive Biomedical Physics*. [S.l.]: Elsevier Science, 2014. ISBN 9780444536334.

CAMPOS-TABERNER, M. et al. Global estimation of biophysical variables from google earth engine platform. *Remote Sensing*, MDPI, v. 10, n. 8, p. 1167, 2018.

CANTALICE, L. R. *Gestão Hídrica do Reservatório Sumé-PB: Potencialidades e Fragilidades*. 2010. 82 p. Dissertação (Mestrado) — Universidade Federal de Campina Grande, Campina Grande-PB, 2010.

CHEN, Y. et al. Extraction of urban water bodies from high-resolution remote-sensing imagery using deep learning. *Water*, v. 10, n. 5, 2018. ISSN 2073-4441. Disponível em: <<https://www.mdpi.com/2073-4441/10/5/585>>.

CORREIA, J. das N. et al. Barragem argemiro de figueireso (acauã): Perenização do baixo paraíba e desenvolvimento econômico. II Congresso Internacional da Diversidade do Semiárido, 2007.

COSTA, S. de O. P. *Avaliação das perspectivas Socioeconômicas e Ambientais do Açude Grande na Cidade de Cajazeiras/PB: um estudo de caso*. 2010. 180 p. Dissertação (Mestrado) — Universidade Federal de Campina Grande, Campina Grande, PB, 2010.

CUNHA, A. P. et al. Extreme drought events over brazil from 2011 to 2019. *Atmosphere*, v. 10, 10 2019.

- DINIZ, C. et al. A large-scale deep-learning approach for multi-temporal aqua and salt-culture mapping. *Remote Sensing*, v. 13, p. 1415, 04 2021.
- DNOCS. Departamento Nacional de Obras Contra as Secas. Açude piranhas. Barragem engenheiro Ávidos. 2003.
- DU, Z. et al. Smallholder crop area mapped with a semantic segmentation deep learning method. *Remote Sensing*, v. 11, p. 888, 04 2019.
- DUAN, Z.; BASTIAANSSEN, W. Estimating water volume variations in lakes and reservoirs from four operational satellite altimetry databases and satellite imagery data. *Remote Sensing of Environment*, v. 134, p. 403–416, 2013. ISSN 0034-4257.
- DUGDALE, S. A practitioner's guide to thermal infrared remote sensing of rivers and streams: recent advances, precautions and considerations. *Wiley Interdisciplinary Reviews: Water*, 03 2016.
- EMDE, C. et al. The libradtran software package for radiative transfer calculations (version 2.0.1). *Geoscientific Model Development*, v. 9, p. 1647–1672, 05 2016.
- ESA. *User Guides - Sentinel-2 MSI - Sentinel Online*. 2022. Disponível em: <<https://sentinel.esa.int/web/sentinel/user-guides/sentinel-2-msi>>.
- FARIAS, R. de S. *Classificação e Segmentação da Região Patológica da COVID-19 em Radiografias do Tórax Usando Redes Neurais Convolucionais*. 2023. 123 p. Dissertação (Mestrado) — Instituto Federal de Educação da Paraíba, João Pessoa, PB, 2023.
- FERNANDES, B. J. T. *Redes Neurais com Extração Implícita de Características para Reconhecimento de Padrões Visuais*. 2013. 155 p. Tese (Doutorado) — Universidade Federal de Pernambuco, Recife, 2013.
- FREITAS, G. M. A. de. *Caracterização Geomorfológica e Morfométrica da Folha Alhandra (1:25.000)*. 2012. 129 p. Dissertação (Mestrado) — Universidade Federal da Paraíba, João Pessoa, PB, 2012.
- GAO, H. et al. An effective modified water extraction method for landsat-8 oli imagery of mountainous plateau regions. *IOP Conference Series: Earth and Environmental Science*, v. 34, p. 012010, 04 2016.
- GOLDBARG, M. A. S. D. S. *Análise de Técnicas de Compressão em Redes Neurais Profundas por Poda em Dataset de Imagens*. 2021. 49 p. Dissertação (Mestrado) — Universidade Federal do Rio Grande do Norte, Natal – RN, 2021.
- GORELICK, N. et al. Google earth engine: Planetary-scale geospatial analysis for everyone. *Remote sensing of Environment*, Elsevier, v. 202, p. 18–27, 2017.
- GOURGOULETIS, N. et al. Estimating reservoir storage variations by combining sentinel-2 and 3 measurements in the yliki reservoir, greece. *Remote Sensing*, v. 14, n. 8, 2022. ISSN 2072-4292. Disponível em: <<https://www.mdpi.com/2072-4292/14/8/1860>>.
- GUYON, I.; ELISSEEFF, A. An introduction to feature extraction. In: GUYON, I. et al. (Ed.). *Feature Extraction*. [S.l.]: Springer, 2006, (Studies in Fuzziness and Soft Computing, v. 207). p. 1–25. ISBN 978-3-540-35488-8.

HAFEMANN, L. G. *An analysis of deep neural networks for texture classification*. 11 2014. 89 p. Tese (Doutorado), 11 2014.

HAYKIN, S. *Redes Neurais: Princípios e Prática*. Bookman Editora, 2001. ISBN 9788577800865. Disponível em: <<https://books.google.com.br/books?id=bhMwDwAAQBAJ>>.

INC, G. Google earth engine. 2022. Disponível em: <<https://earthengine.google.com>>.

KANG, K.; WANG, X. Fully convolutional neural networks for crowd segmentation. *ArXiv*, abs/1411.4464, 2014.

KAUSHAL, V. et al. Learning from less data: A unified data subset selection and active learning framework for computer vision. In: IEEE. *2019 IEEE Winter Conference on Applications of Computer Vision (WACV)*. [S.l.], 2019. p. 1289–1299.

KINGMA, D. P.; BA, J. *Adam: A Method for Stochastic Optimization*. 2017.

KLEIN, I. et al. Global waterpack – a 250 m resolution dataset revealing the daily dynamics of global inland water bodies. *Remote Sensing of Environment*, v. 198, p. 345–362, 09 2017.

KO, B.; KIM, H.; NAM, J. Classification of potential water bodies using landsat 8 oli and a combination of two boosted random forest classifiers. *Sensors*, v. 15, p. 13763–13777, 2015.

LECUN, Y.; BENGIO, Y.; HINTON, G. Deep learning. *Nature*, v. 521, p. 436–44, 05 2015.

LIU, W. et al. An automatic extraction architecture of urban green space based on deeplabv3plus semantic segmentation model. In: . [S.l.: s.n.], 2019. p. 311–315.

LIU, W. T. H. *Aplicações de Sensoriamento Remoto*. [S.l.]: Oficina de Textos, São Paulo, 2015.

LOPES, H. et al. Comportamento espacial da clorofila-a no reservatório de itaparica, rio sao francisco. *Engenharia Sanitaria e Ambiental*, v. 20, p. 475–484, 11 2015.

LOUIS, J. et al. Sentinel-2 sen2cor: L2a processor for users. *European Space Agency, (Special Publication) ESA SP*, MDPI, p. p. 9–13, 2016.

LUO, X.; TONG, X.; HU, Z. An applicable and automatic method for earth surface water mapping based on multispectral images. *International Journal of Applied Earth Observation and Geoinformation*, v. 103, p. 102472, 2021.

LÓ, T. B. *Mapeamento de uso e cobertura da Terra utilizando sensoriamento remoto e redes neurais convolucionais*. 2022. 164 p. Dissertação (Mestrado) — Universidade Estadual do Oeste do Paraná, Cascavel, 2022.

MACHADO, M.; BAPTISTA, G. Sensoriamento remoto como ferramenta de monitoramento da qualidade da água do lago paranoá (DF). *Engenharia Sanitaria e Ambiental*, v. 21, 04 2016.

- MAIO, A. D. et al. Formação continuada de professores: Sensoriamento remoto. Brasília, p. 82, 2008.
- MAMEDE, G. L. et al. Overspill avalanching in a dense reservoir network. *Proceedings of the National Academy of Sciences*, National Acad Sciences, v. 109, n. 19, p. 7191–7195, 2012.
- MARTINS, E. et al. Utilização de imagens cbers para mapeamento dos espelhos d’água do brasil. *Anais do XVIII Simpósio Brasileiro de Sensoriamento Remoto*, p. 969–976, 04 2007.
- MAYER, T. et al. Deep learning approach for sentinel-1 surface water mapping leveraging google earth engine. *ISPRS Open Journal of Photogrammetry and Remote Sensing*, v. 2, p. 100005, 2021. ISSN 2667-3932.
- MEDEIROS, A. M. T. de; BRITO, A. C. de. A seca no estado da paraíba – impactos e ações de resiliência. *A seca nos Estados*, 2017.
- MIKOŁAJCZYK, A.; GROCHOWSKI, M. Data augmentation for improving deep learning in image classification problem. In: IEEE. *2018 international interdisciplinary PhD workshop (IIPhDW)*. [S.l.], 2018. p. 117–122.
- MIRANDA, M. et al. Classification of the water volume of dams using heterogeneous remote sensing images though a deep convolutional neural network. In: . [S.l.: s.n.], 2021.
- MORATO, R. G.; KAWAKUBO, F. S.; LUCHIARI, A. Avaliação da qualidade de vida urbana no município de embu por meio de técnicas de geoprocessamento. *GEOUSP Espaço e Tempo (Online)*, v. 12, n. 2, p. 149–163, dez. 2008.
- MOREIRA, M. et al. Caracterização geológico-geotécnica e piezometria do aquífero semi-confinado barreiras do município de natal-rn. *Anais do XX Congresso Brasileiro de Águas Subterrâneas/XXI Encontro Nacional de Perfuradores de Poços*, 11 2018.
- MOU, L.; GHAMISI, P.; ZHU, X. X. Deep recurrent neural networks for hyperspectral image classification. *IEEE Transactions on Geoscience and Remote Sensing*, IEEE, v. 55, n. 7, p. 3639–3655, 2017.
- NAMIKAWA, L. Imagens landsat 8 para monitoramento de volume de água em reservatórios: Estudo de caso nas barragens jaguari e jacareí do sistema cantareira. *Anais do XVII Simpósio Brasileiro de Sensoriamento Remoto*, 01 2015.
- NOVO, E. M. L. M. *Sensoriamento remoto: princípios e aplicações*. [S.l.]: Editora Edgard Bücher Ltda, São Paulo, 1992.
- NOVO, E. M. L. M.; PONZONI, F. J. *Introdução ao sensoriamento remoto*. São José dos Campos, 2001. 68 p.
- NÓBREGA, M. R. R. et al. Emprego da Álgebra de bandas para o monitoramento dos espelhos d’água no estado do ceará. *Anais do XIX Simpósio Brasileiro de Sensoriamento Remoto.*, 11 2019.
- PARAÍBA. Governo do Estado da Paraíba. Plano estadual de recursos hídricos da paraíba: Rf-02 b - Diagnóstico atual dos recursos hídricos. Agência Executiva de Gestão das Águas do Estado da Paraíba, João Pessoa, p. 549, 2022.

PARKS, S. A. et al. Mean composite fire severity metrics computed with google earth engine offer improved accuracy and expanded mapping potential. *Remote Sensing*, MDPI, v. 10, n. 6, p. 879, 2018.

PEDRASSOLI, J. C. *Análise orientada a objeto para detecção de favelas e classificação do uso do solo em Taboão da Serra/SP*. 2011. 116 p. Dissertação (Mestrado) — Universidade de São Paulo, São Paulo, 2011.

PEKEL, J.-F. et al. High-resolution mapping of global surface water and its long-term changes. *Nature*, v. 540, 12 2016.

PERENNOU, C. et al. Chapter six - mapping mediterranean wetlands with remote sensing: A good-looking map is not always a good map. In: BOHAN, D. A. et al. (Ed.). *Next Generation Biomonitoring: Part 1*. [S.l.]: Academic Press, 2018, (Advances in Ecological Research, v. 58). p. 243–277.

PHYS-ORG. *Remote Sensing and Forest Inventories Contribute to Saving Tropical Forests*. 2016.

PICKENS, A. H. et al. Mapping and sampling to characterize global inland water dynamics from 1999 to 2018 with full landsat time-series. *Remote Sensing of Environment*, v. 243, 2020. ISSN 0034-4257.

POSTEL, S.; DAILY, G.; EHRLICH, P. Human appropriation of renewable fresh water. *Science*, v. 271, p. 785–788, 02 1996.

REFAEILZADEH, P.; TANG, L.; LIU, H. Cross-validation. *Encyclopedia of Database Systems*, v. 532–538, p. 532–538, 01 2009.

REN, J.; GREEN, M.; HUANG, X. Chapter 8 - from traditional to deep learning: Fault diagnosis for autonomous vehicles. In: ZHANG, D.; WEI, B. (Ed.). *Learning Control*. Elsevier, 2021. p. 205–219. ISBN 978-0-12-822314-7. Disponível em: <<https://www.sciencedirect.com/science/article/pii/B9780128223147000134>>.

RODRIGUES, I. et al. Classifying covid-19 positive x-ray using deep learning models. *IEEE Latin America Transactions*, v. 19, n. 6, p. 884–892, Jun. 2021. Disponível em: <<https://latamt.ieeer9.org/index.php/transactions/article/view/4202>>.

ROKNI, K. et al. Water feature extraction and change detection using multitemporal landsat imagery. *Remote sensing*, MDPI, v. 6, n. 5, p. 4173–4189, 2014.

RONNEBERGER, O.; FISCHER, P.; BROX, T. *U-Net: Convolutional Networks for Biomedical Image Segmentation*. arXiv, 2015. Disponível em: <<https://arxiv.org/abs/1505.04597>>.

SANTOS, C. A. S. D. *Reconhecimento de Imagens de Marcas de Gado Utilizando Redes Neurais Convolucionais e Máquinas de Vetores de Suporte*. 2017. 136 p. Dissertação (Mestrado) — Universidade Federal do Pampa, Alegrete, 2017.

SCHMIDHUBER, J. Deep learning in neural networks: An overview. *Neural Networks*, v. 61, p. 85–117, 2015. ISSN 0893-6080. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S0893608014002135>>.

SEIRHMA. Secretaria de Estado da Infraestrutura, dos Recursos Hídricos e do Meio Ambiente. Marco de gestão social e ambiental do projeto de segurança hídrica da paraíba - PSH/PB. Governo da Paraíba, p. 138, 2021.

SILVA, G. L. F. d. *Diagnóstico de nódulos pulmonares em imagens de tomografia computadorizada usando redes neurais convolucionais evolutivas*. 2017. Dissertação (Mestrado), 2017. Coordenação do Curso de Ciências da Computação/CCET. Disponível em: <<http://tedebc.ufma.br:8080/jspui/handle/tede/1534>>.

SILVA, J. C. D. M. E. *Estudo Comparativo da Qualidade da Água dos Reservatórios Fluviais de Marés e Gramame-Mamuaba na Paraíba*. 2018. 97 p. Dissertação (Mestrado) — Universidade Federal da Paraíba, João Pessoa-PB, 2018.

SILVA, L. M. D. D.; SILVA, T. C. D.; FILGUEIRA, H. J. A. Análises de risco aplicadas às barragens de gramame-mamuaba na paraíba. *XIII Simpósio de Recursos Hídricos do Nordeste*, Aracajú, 2016.

SILVER, D. et al. Mastering the game of go with deep neural networks and tree search. *Nature*, v. 529, p. 484–489, 01 2016.

SOBREIRA, L. C. *Expansão Urbana e Variações Mesoclimáticas em João PESSOA-PB*. 2010. 83 p. Dissertação (Mestrado) — Universidade Federal da Paraíba, João Pessoa, PB, 2010.

SOTHE, C. et al. Evaluating sentinel-2 and landsat-8 data to map sucessional forest stages in a subtropical forest in southern brazil. *Remote Sensing*, v. 9, p. 838, 08 2017.

SOUZA, C. et al. Long-term annual surface water change in the brazilian amazon biome: Potential links with deforestation, infrastructure development and climate change. *Water*, v. 11, p. 566, 03 2019.

SOUZA, J. R. de; PAIXÃO, M. S.; CARVALHO, J. dos S. Avaliação multitemporal do espelho d'água do açude ingazeiras usando processamento digital de imagens e dados de pluviosidade. *Revista Científica da Escola de Gestão e Negócios*, 2019.

SRIVASTAVA, N. et al. Dropout: A simple way to prevent neural networks from overfitting. *Journal of Machine Learning Research*, v. 15, p. 1929–1958, 06 2014.

SUDRE, C. et al. Generalised dice overlap as a deep learning loss function for highly unbalanced segmentations. *Lecture Notes in Computer Science (including subseries Lecture Notes in Artificial Intelligence and Lecture Notes in Bioinformatics)*, Springer, v. 10553 LNCS, p. 240–248, set. 2017. ISSN 0302-9743.

SUMÉ. Plano Municipal de Gestão Integrada de Resíduos Sólidos de Sumé-PB. Prefeitura Municipal de Sumé, Sumé, PB, p. 365, 2014.

TAN, Z. et al. Mapping inundation dynamics in a heterogeneous floodplain: Insights from integrating observations and modeling approach. *Journal of Hydrology*, v. 572, p. 148–159, 2019. ISSN 0022-1694. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S0022169419301969>>.

TASSI, A.; VIZZARI, M. Object-oriented lulc classification in google earth engine combining snic, glcm, and machine learning algorithms. *Remote Sensing*, MDPI, v. 12, n. 22, p. 3776, 2020.

TIU, E. Metrics to evaluate your semantic segmentation model. *Towards Data Science*, 2019.

TORRES, D. L. et al. Applying fully convolutional architectures for semantic segmentation of a single tree species in urban environment on high resolution uav optical imagery. *Sensors*, v. 20, p. 563, 01 2020.

TOURIAN, M. et al. A spaceborne multisensor approach to monitor the desiccation of lake urmia in iran. *Remote Sensing of Environment*, v. 156, p. 349–360, 2015. ISSN 0034-4257. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S0034425714004027>>.

UN-WATER. Water security the global water agenda - a un-water analytical brief. In: . Ontário-Canadá: [s.n.], 2013. p. 37 p.

VILELA, M. A. M. A. *Metodologia para monitoramento da qualidade de água de reservatórios utilizando sensoriamento remoto*. 2010. 123 p. Dissertação (Mestrado) — Universidade Federal de Uberlândia, Uberlândia, 2010.

WAGNER, F. et al. Using the u-net convolutional network to map forest types and disturbance in the atlantic rainforest with very high resolution images. *Remote Sensing in Ecology and Conservation*, v. 5, 03 2019.

WANG, G. et al. Water identification from high-resolution remote sensing images based on multidimensional densely connected convolutional neural networks. *Remote Sensing*, v. 12, n. 5, 2020. ISSN 2072-4292. Disponível em: <<https://www.mdpi.com/2072-4292/12/5/795>>.

WANG, Z.; ZOU, Y.; LIU, P. X. Hybrid dilation and attention residual u-net for medical image segmentation. *Computers in Biology and Medicine*, v. 134, p. 104449, 2021. ISSN 0010-4825. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S0010482521002432>>.

XU, H. et al. Lockdown effects on total suspended solids concentrations in the lower min river (china) during covid-19 using time-series remote sensing images. *International Journal of Applied Earth Observation and Geoinformation*, v. 98, p. 102301, 01 2021.

YAN, J. et al. A cloud-based remote sensing data production system. *Future Generation Computer Systems*, v. 86, 03 2017.

YAO, F. et al. Constructing long-term high-frequency time series of global lake and reservoir areas using landsat imagery. *Remote Sensing of Environment*, v. 232, p. 111210, 2019. ISSN 0034-4257. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S0034425719302238>>.

ZHANG, P. et al. Urban land use and land cover classification using novel deep learning models based on high spatial resolution satellite imagery. *Sensors*, v. 18, p. 3717, 11 2018.

ZHANG, S. et al. Mapping regional surface water volume variation in reservoirs in northeastern brazil during 2009–2017 using high-resolution satellite images. *Science of The Total Environment*, v. 789, p. 147711, 2021. ISSN 0048-9697. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S0048969721027820>>.

ZHANG, X. et al. How well do deep learning-based methods for land cover classification and object detection perform on high resolution remote sensing imagery? *Remote Sensing*, v. 12, p. 417, 01 2020.

ZHAO, S. et al. Multilevel threshold image segmentation with diffusion association slime mould algorithm and renyi's entropy for chronic obstructive pulmonary disease. *Computers in Biology and Medicine*, v. 134, p. 104427, 2021. ISSN 0010-4825. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S0010482521002213>>.

ANEXO A – CURVAS COTA × ÁREA × VOLUME

Tabela 14: Cota x Área x Volume do Reservatório Engenheiro Ávidos.

Cota (m)	Área inundada (m ²)	Volume acumulado (m ³)
290	560.192,0	160.100,00
291	812.942,0	852.800,00
292	1.092.616,0	1.891.800,00
293	1.399.312,0	3.268.800,00
294	1.733.742,0	4.983.500,00
295	2.097.230,0	7.042.600,00
296	2.491.712,0	9.460.700,00
297	2.919.742,0	12.259.800,00
298	3.384.483,0	13.951.000,00
299	3.889.712,0	17.847.500,00
300	4.439.822,0	21.744.000,00
301	5.039.816,0	26.776.665,00
302	5.695.312,0	31.911.000,00
303	6.412.542,0	38.225.000,00
304	7.198.359,0	44.539.000,00
305	8.060.192,0	52.375.500,00
306	9.006.142,0	60.212.000,00
307	10.044.888,0	70.353.000,00
308	11.185.712,0	80.494.000,00
309	12.438.542,0	94.104.000,00
310	13.813.897,0	107.714.000,00
311	15.322.912,0	125.350.000,00
312	16.977.341,0	142.986.000,00
313	18.789.549,0	164.238.500,00
314	20.772.512,0	185.491.000,00
315	22.939.821,0	211.073.500,00
316	25.305.683,0	236.656.000,00
317	27.884.911,0	255.000.000,00
318	30.692.941,0	270.803.800,00
319	33.745.816,0	309.752.400,00
320	37.060.192,0	344.661.000,00

Fonte: AESA (2023).

Tabela 15: Cota x Área x Volume do Reservatório Argemiro de Figueiredo.

Cota (m)	Área inundada (m ²)	Volume acumulado (m ³)
90	138.939,00	0,00
91	169.297,00	335.136,00
92	219.737,00	944.519,00
93	290.924,00	1.497.351,00
94	383.457,00	2.033.709,00
95	497.860,00	2.592.511,00
96	634.592,00	3.211.516,00
97	794.041,00	3.927.325,00
98	976.526,00	4.775.377,00
99	1.182.294,00	5.789.957,00
100	1.411.527,00	7.004.187,00
101	1.664.334,00	8.450.033,00
102	1.940.756,00	10.158.300,00
103	2.240.763,00	12.158.635,00
104	2.564.259,00	14.479.528,00
105	2.911.075,00	17.148.306,00
106	3.280.974,00	20.191.142,00
107	3.673.650,00	23.633.046,00
108	4.088.726,00	27.497.872,00
109	4.525.756,00	31.808.314,00
110	4.984.227,00	36.585.907,00
111	5.463.553,00	41.851.027,00
112	5.963.081,00	47.622.892,00
113	6.482.087,00	53.919.561,00
114	7.019.778,00	60.757.934,00
115	7.575.292,00	68.153.751,00
116	8.147.698,00	76.121.596,00
117	8.735.993,00	84.674.890,00
118	9.339.108,00	93.825.900,00
119	9.955.903,00	103.585.730,00
120	10.585.167,00	113.964.327,00
121	11.225.622,00	124.970.480,00
122	11.875.919,00	136.611.817,00
123	12.534.640,00	148.894.817,00
124	13.200.298,00	161.824.768,00
125	13.871.335,00	175.405.846,00
126	14.546.126,00	189.641.037,00
127	15.222.975,00	204.532.176,00
128	15.900.116,00	220.079.939,00
129	16.575.715,00	236.283.843,00

**Tabela 15: Cota x Área x Volume do Reservatório Argemiro de Figueiredo.
(continuação)**

Cota (m)	Área inundada (m ²)	Volume acumulado (m ³)
130	17.247.867,00	253.142.247,00
131	17.914.599,00	270.652.350,00
132	18.573.868,00	288.810.194,00
133	19.223.560,00	307.610.660,00
134	19.861.495,00	327.047.471,00
135	20.485.420,00	347.113.191,00
136	21.093.015,00	367.799.227,00
137	21.681.889,00	389.095.824,00
138	22.249.582,00	410.992.070,00
139	22.311.239,00	433.475.894,00
140	23.311.239,00	456.534.067,00

Fonte: AESA (2023).

Tabela 16: Cota x Área x Volume do Reservatório Lagoa do Arroz.

Cota (m)	Área inundada (m ²)	Volume acumulado (m ³)
77	0,00	0,00
78	7.500,00	3.750,00
79	80.000,00	47.500,00
80	172.500,00	173.750,00
81	240.500,00	380.250,00
82	304.000,00	652.500,00
83	359.000,00	984.000,00
84	487.000,00	1.407.000,00
85	592.000,00	1.946.500,00
86	637.000,00	2.561.000,00
87	761.250,00	3.260.125,00
88	953.500,00	4.117.500,00
89	1.221.000,00	5.204.750,00
90	1.573.000,00	6.651.750,00
91	2.060.000,00	8.518.250,00
92	2.509.500,00	10.803.000,00
93	3.212.000,00	13.663.750,00
94	4.703.000,00	17.621.250,00
95	4.945.500,00	22.445.500,00
96	5.420.000,00	27.628.250,00

Tabela 16: Cota x Área x Volume do Reservatório Lagoa do Arroz. (*continuação*)

Cota (m)	Área inundada (m ²)	Volume acumulado (m ³)
97	6.237.500,00	33.457.000,00
98	7.318.000,00	40.234.700,00
99	8.570.500,00	48.179.000,00
100	10.245.500,00	57.587.000,00
101	11.369.000,00	68.394.250,00
102	12.284.000,00	80.220.750,00
103	13.616.500,00	93.171.000,00
104	15.257.500,00	107.607.750,00

Fonte: AESA (2023).

Tabela 17: Cota x Área x Volume do Reservatório Gramame/Mamuaba.

Cota (m)	Área inundada (m ²)	Volume acumulado (m ³)
17	0,00	0,00
18	104.049,00	20.000,00
19	208.098,00	85.000,00
20	437.859,00	299.000,00
21	667.620,00	722.000,00
22	914.124,50	1.442.000,00
23	1.160.629,00	2.537.000,00
24	1.657.749,00	4.048.000,00
25	2.154.869,00	6.122.000,00
26	2.650.610,50	8.945.000,00
27	3.146.352,00	11.964.000,00
28	3.717.510,00	15.454.000,00
29	4.288.668,00	19.721.000,00
30	4.931.510,50	23.305.000,00
31	5.574.353,00	28.646.000,00
32	6.285.896,00	34.651.000,00
33	6.997.439,00	41.238.000,00
34	7.775.214,50	48.492.000,00
35	8.552.990,00	56.937.000,00
36	9.271.156,25	65.885.000,00
37	10.015.815,50	75.764.000,00

Fonte: AESA (2023).

Tabela 18: Cota x Área x Volume do Reservatório Sumé.

Cota (m)	Área inundada (m ²)	Volume acumulado (m ³)
59.4	0,00	0,00
60	5.250,00	1.575,00
61	26.500,00	17.450,00
62	93.000,00	77.200,00
63	216.250,00	231.825,00
64	582.000,00	630.950,00
65	1.004.000,00	1.423.950,00
66	1.464.750,00	2.658.325,00
67	2.039.750,00	4.410.575,00
68	2.673.250,00	6.767.075,00
69	3.325.250,00	9.766.325,00
70	3.897.750,00	13.377.825,00
71	4.623.000,00	17.638.200,00
72	5.434.250,00	22.666.825,00
73	6.311.000,00	28.539.450,00
74	7.253.500,00	35.321.700,00
75	8.317.250,00	43.107.075,00
75.2	8.518.250,00	44.864.100,00

Fonte: AESA (2023).

Tabela 19: Cota x Área x Volume do Reservatório Marés.

Cota (m)	Área inundada (m ²)	Volume acumulado (m ³)
8	50.520,00	40.350,00
10	191.440,00	267.353,00
12	244.880,00	720.513,00
14	316.240,00	1.262.073,00
16	375.200,00	1.952.567,00
16.5	394.343,00	2.136.637,00
18	444.560,00	2.774.314,00
20	498.560,00	3.713.260,00

Fonte: AESA (2023).